

Quelle: Schaffer, J., Weidenbach, M. (2019). Agentenbasierte Steuerung Fahrerloser Transportsysteme im Umfeld von Industrie 4.0. In: ten Hompel, M., Vogel-Heuser, B., Bauernhansl, T. (eds) Handbuch Industrie 4.0. Springer Reference Technik (). Springer Vieweg, Berlin, Heidelberg. https://doi.org/10.1007/978-3-662-45537-1_100-1

Neurosymbolische KI- Das Beste aus allen Welten (?)


WS 2025/26

Prof. Dr. Klemens Waldhör

Inhalt

Themen

- Neurosymbolische KI



3

Neurosymbolische KI- Das Beste aus allen Welten (?)

Literatur

Bhuyan, B.P., Ramdane-Cherif, A., Singh, T.P., and Tomar, R. 2025. Neuro-symbolic artificial intelligence. Bridging logic and learning. Studies in computational intelligence volume 1176. Springer, Singapore.

Ruhlig, K. 2024. Neurosymbolische künstliche Intelligenz. Fraunhofer.

<https://esut.de/2024/11/fachbeitraege/54269/fraunhofer-neurosymbolische-kuenstliche-intelligenz/> Shakarian, P. 2023. Neuro Symbolic Reasoning and Learning. SpringerBriefs in Computer Science Series. Springer, Cham.

THOMAS, G.M. 2025. NEUROSYMBOLIC ARTIFICIAL INTELLIGENCE SECOND EDITION : bridging symbolic reasoning and neural... networks. ADMIT HUB REF SERVICE PR, [S.I.].

Vina, A. Nov 18, 2025T08:00:00+08:00. The Emerging Field of Neuro-Symbolic AI: An Introduction (Nov 18, 2025T08:00:00+08:00). <https://www.ultralytics.com/de/blog/an-introduction-to-the-emerging-field-of-neuro-symbolic-ai#:~:text=Vor%2D%20und%20Nachteile%20der%20neurosymbolischen%20KI.%20Hier,die%20mehrstufiges%20Denken%2C%20Planung%2C%20Regelbefolgung%20und%20den>

Zeitschrift: <https://journals.sagepub.com/home/nai>: Neurosymbolic Artificial Intelligence

Einführung und Motivation: Neuro-Symbolische KI: Der nächste Evolutionsschritt?

Symbolische KI (Erste Welle, ca. 1950-1980):

- **Stärke**
 - arbeitet mit explizitem, logisch beschriebenem Wissen
 - Regeln, Logik, Ontologien, Wissensgraphen
 - gut erklärbar, kann mit abstrakten Konzepten und Schlussfolgern umgehen
- **Schwäche**
 - Bruch mit der unstrukturierten, realen Welt
 - schlecht im Lernen aus Rohdaten
 - manueller Programmieraufwand

Neuronale KI / Deep Learning (Zweite Welle, ca. 1990-heute):

- **Stärke**
 - Mustererkennung aus riesigen Datenmengen (Wahrnehmung)
 - sehr gut für Aufgaben wie Bild-, Sprach- oder Mustererkennung
- **Schwäche**
 - Black Box (Mangelnde Erklärbarkeit/Transparenz)
 - Mangel an logischem Reasoning und Abstraktion
 - Halluzinationen bei Sprachmodellen.

Die Lücke

- Echte menschenähnliche Intelligenz benötigt Wahrnehmung UND Logik

Verbindet beide Welten zu einem System, das:

- wahrnimmt (über neuronale Netze),
- versteht und schlussfolgert (über symbolische Logik),
- lernt, aber trotzdem erklärbar bleibt.

Definition Neuro-Symbolische KI

Ein hybrider Ansatz, der die lernfähigen neuronalen Architekturen mit strukturiertem, regelbasiertem (symbolischem) Wissen kombiniert.

Warum ist der Ansatz spannend?

- Verbindet Robustheit und Lernfähigkeit neuronaler Netze
- mit Transparenz, Logik und Abstraktion symbolischer Systeme
- geeignet für Bereiche, wo Erklärbarkeit + Lernfähigkeit nötig sind, z. B.:
 - Medizin
 - Recht
 - Industrieautomatisierung
 - Wissensintensive Aufgaben (Wissensgraph + LLMs)

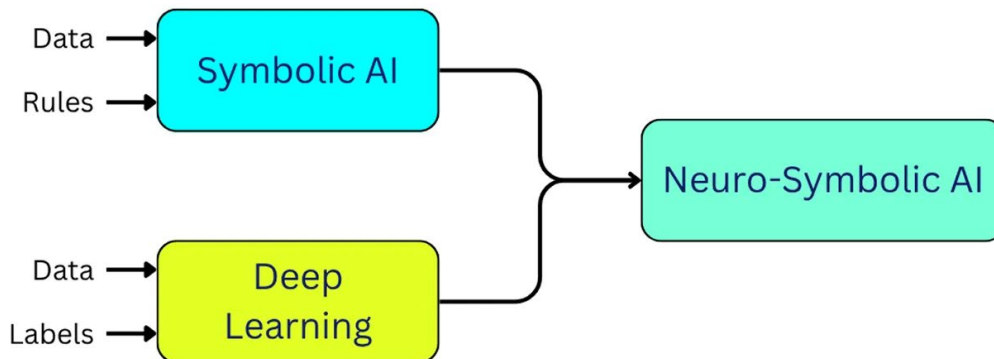
Grundlagen und Architekturen

Kernkomponenten der Neuro-Symbolische KI:

- **Neuronale Komponente:**
Verarbeitet unstrukturierte Daten (Bilder, Text, Sprache) und extrahiert niedrigstufige Muster (z. B. Objekterkennung).
- **Symbolische Komponente:**
Repräsentiert Wissen (z. B. in Form von logischen Regeln, Wissensgraphen) und führt logisches Schließen (Reasoning) durch.

Integrationsmechanismen (Beispiele):

- **Regel-gesteuertes Lernen:**
Das neuronale Netz lernt, Regeln zu generieren oder zu befolgen.
- **Wissen-informiertes Lernen:**
Symbolisches Wissen (z. B. ein Wissensgraph) beeinflusst/reguliert den Lernprozess des neuronalen Netzes.
- **End-to-End-Integration:**
Neuronale und symbolische Teile arbeiten in einer einzigen Architektur zusammen (z. B. bei der visuellen Fragebeantwortung, wo ein CNN Objekte erkennt und ein logisches Modul die Beziehungen schlussfolgert).



Quelle Bild: <https://www.ultralytics.com/de/blog/an-introduction-to-the-emerging-field-of-neuro-symbolic-ai#:~:text=Vor%2D%20und%20Nachteile%20der%20neurosymbolischen%20KI,%20Hier,die%20mehrstufiges%20Denken%2C%20Planung%2C%20Regelbefolgung%20und%20den>

Beispiel: Objekterkennung und Zutritt – Teil 1

Szenario:

Ein intelligentes System soll erkennen, ob in einem Bild eine Person zu sehen ist, die einen Helm trägt, und entscheiden, ob der Zutritt zu einer Baustelle erlaubt ist.

Neuronaler Teil (Perception)

Ein CNN/ViT/LLM-Vision erkennt aus dem Bild folgende Objekte:

- Person
- Helm
- Warnweste (vielleicht)

```
{  
  "person_detected": true,  
  "helmet_detected": false,  
  "vest_detected": true  
}
```

Das Netz „sieht“, aber **es versteht noch keine Regeln**.

Symbolischer Teil (Knowledge + Reasoning)

Eine Wissensbasis enthält Expertenregeln:

Das System **entscheidet nach formaler Logik**, welche Sicherheitsvorschriften gelten.

```
IF person_detected = true AND helmet_detected = false  
THEN access_allowed = false.
```

```
IF person_detected = true AND helmet_detected = true  
THEN access_allowed = true.
```

```
IF person_detected = false  
THEN access_allowed = false.
```

Beispiel: Objekterkennung und Zutritt -Teil 2

Neuro-Symbolische Kombination

Schritt 1: Neural → Symbolic

- Die erkannten Objekte werden als Fakten in die Wissensbasis übergeben:

```
FACT person_detected.  
FACT vest_detected.  
FACT NOT helmet_detected.
```

Schritt 2: Symbolic Reasoning

- Das System leitet ab:
helmet_detected = false → required_equipment_missing → access_not_allowed

Schritt 3: Output

- Ausgabe:
„Zutritt nicht erlaubt – Helm fehlt.“

Neuronale KI	Symbolische KI	Neuro-Symbolic KI
erkennt Muster (Helm, Person)	kennt Regeln	verbindet beides
unscharf, probabilistisch	exakt, erklärbar	robust + erklärbar
Black Box	transparent	erklärbare KI

Visuelle Fragebeantwortung (VQA)

Systeme können nicht nur Objekte in einem Bild erkennen, sondern auch komplexe logische Fragen darüber beantworten.

Beispiel: LLM als „Planer“ + Symbolsystem als Tool

Das LLM ist ein Agent, der symbolische Tools aufruft

LLM liest eine Aufgabe: „Plane Schaltzeiten für Maschinen unter Sicherheitsregeln.“

LLM entscheidet:

„Ich rufe jetzt den Constraint-Solver auf.“

„Ich frage den Wissensgraph zu Normen ab.“

- Symbolisches System (z. B. Prolog, Z3, ASP-Solver) macht den korrekten, formalen Schluss.
- LLM formuliert die Antwort, erklärt die Lösung, baut Visualisierungen.
- Das ist im Prinzip das, was viele „Agentic AI“-Frameworks machen:
LLM = Policy, Controller, natürlicher Sprachlayer,
Symbolik = Zuverlässiger Rechner / Prüfer.

Beispiel: LLM + Wissensgraph / Ontologie (RAG + Logik)

- Nutzerfrage → LLM analysiert, welche Entitäten/Relationen relevant sind.
- Wissensgraph wird abgefragt (SPARQL, Cypher, ...).
- Ergebnisse werden nach logischen Regeln gefiltert (z. B. Konsistenzprüfung).
- LLM erzeugt aus den geprüften Fakten eine gut lesbare Antwort.

Wichtig:

- LLM darf keine Fakten halluzinieren, sondern nur über KG-Tatsachen + Regeln sprechen.

Auch hier wieder Agentic AI

Beispiel: Analyse von Verkaufsdaten + Regelprüfung (Business Analytics)

Ziel

Ein System soll Verkaufszahlen analysieren und automatisch melden, ob Auffälligkeiten bestehen
z. B. Verstöße gegen interne KPIs, fehlerhafte Buchungen, Marge unter Grenzwert, ungewöhnliche Trends.

Input (Daten aus BI-System)

Ein Dashboard liefert eine Zusammenfassung:

„Umsatz Q3 im Segment ‚Premium Bikes‘ liegt bei 420 T€ (-31 % ggü. Vorjahr).
Die Marge beträgt 2,8 % statt der erwarteten 10 %.
Die Retourenquote ist auf 14 % gestiegen.“

LLM → Extraktion von Fakten

Das LLM wandelt den Text in strukturierte Werte um

```
{  
  "segment": "Premium Bikes",  
  "umsatz": 420000,  
  "umsatz_delta_yoy": -0.31,  
  "marge": 0.028,  
  "expected_marge": 0.10,  
  "retourenquote": 0.14  
}
```

Symbolische Regeln (KPI-Logik)

Business-Logik-Regeln, sind stabil, transparent und auditiert.

```
IF marge < expected_marge * 0.8  
  THEN WARNUNG("Marge deutlich unter Soll")  
IF umsatz_delta_yoy < -0.15  
  THEN ALARM("Starker Umsatzrückgang")  
IF retourenquote > 0.10  
  THEN HINWEIS("Retourenquote kritisch")
```

Kombination (Neuro-Symbolic Workflow)

Das LLM extrahiert → Symbolsystem entscheidet → LLM erzeugt eine lesbare Zusammenfassung.

Ergebnis Premium Bikes – Q3

- Umsatzrückgang ist mit -31 % kritisch (Regel 2 verletzt)
- Marge liegt mit 2,8 % deutlich unter Unternehmensvorgabe (Regel 1 verletzt)
- Retourenquote (14 %) überschreitet den Grenzwert (Regel 3)

Empfehlung: Ursachenanalyse im Servicebereich; Preispolitik prüfen; Lieferantenfehler oder Qualitätsprobleme möglich.

Vorteile der Neuro-Symbolischen KI

- **Verbesserte Robustheit und Zuverlässigkeit**
Regeln können Fehler in der Mustererkennung abfangen
Autonomes Fahren: Das neuronale Netz erkennt einen Fußgänger, die symbolische Logik prüft, ob die Aktion sicher und legal ist.
- **Erklärbarkeit (XAI)**
Die symbolische Schicht ermöglicht es, den Weg zur Entscheidung nachzuvollziehen und in menschenlesbaren Regeln darzustellen.
- **Bessere Generalisierung (weniger Daten nötig)**
Durch eingebettetes Vorwissen (Regeln) kann das System schneller und besser auf neue, unbekannte Situationen reagieren, da es nicht alles neu lernen muss.
- **Reasoning-Fähigkeit**
Das System kann logische Schlüsse ziehen, Beziehungen verstehen und kausale Zusammenhänge erkennen.

Anwendungsbereiche

Verarbeitung natürlicher Sprache (NLP):

Verbesserung von **Large Language Models (LLMs)**, um Halluzinationen durch die Prüfung logischer oder faktischer Konsistenz mit Wissensgraphen zu reduzieren.

Autonomes Fahren/Robotik:

Die neuronale Schicht erkennt die Umgebung (Ampeln, Fußgänger).

Die symbolische Schicht **plant die Aktion** basierend auf Verkehrsregeln und logischen Einschränkungen.

Medizinische Diagnose und Entscheidungsunterstützung:

Neuronale Netze analysieren medizinische Bilder (MRT, Röntgen).

Symbolische Systeme prüfen die Ergebnisse gegen medizinisches **Expertenwissen** und Patientenakten, um eine fundierte und **erklärbare** Diagnose zu stellen.

Industrie 4.0 / Prozessautomatisierung:

Kombination von Mustererkennung (Maschinelles Sehen) mit formalen Prozessmodellen (z. B. BPMN) zur intelligenten Steuerung und Fehlerkorrektur.

Herausforderungen und Ausblick

Herausforderungen

- **Integration:** Wie lassen sich die kontinuierlichen Outputs neuronaler Netze am besten in diskrete, symbolische Repräsentationen überführen?
- **Skalierbarkeit:** Die Erstellung und Pflege großer, formalisierter Wissensbasen ist aufwändig.
- **Lernen:** Wie können sowohl die neuronalen als auch die symbolischen Komponenten *gemeinsam* und *dynamisch* lernen?

Ausblick

- euro-Symbolische KI wird als die **"dritte Welle der KI"** angesehen, die uns der "echten" allgemeinen künstlichen Intelligenz (AGI) näher bringt.
- Es wird erwartet, dass hybride Systeme die Zukunft dominieren, insbesondere in **sicherheitskritischen** und **erklärungsbedürftigen** Bereichen.

- Neuro-Symbolische KI hat das Potenzial, die Lücken zwischen der statistischen Stärke des Deep Learning und den logischen Fähigkeiten der klassischen KI zu schließen, um erklärbare, robuste und reasoning-fähige Systeme zu schaffen.

Hotel

Ein Hotel analysiert tägliche Berichte. Ein System soll:

Kennzahlen automatisch aus Texten extrahieren (z. B. Auslastung, Stornorate, Kosten)
diese gegen KPI-Regeln prüfen
Handlungsempfehlungen erzeugen

Bearbeiten Sie:

Welche Kennzahlen sollten aus Hotelberichten extrahiert werden?
Formulieren Sie 3–5 symbolische Regeln (z. B. Storno, Kosten, Rabatte).
Warum reicht ein rein neuronales System nicht aus?

Entwerfen Sie eine Architektur mit drei Komponenten:

Neuronale Komponente zur Extraktion (LLM)
Symbolisches Regelwerk (Hotel-KPIs, Compliance)
Pipeline: Bericht → LLM → Fakten → Regeln → Empfehlung

Diskutieren Sie:

Vorteile für das Hotel (Automatisierung, Revenue Management).
Risiken (Extraktionsfehler, Regelkollisionen).
Einsatzfelder: Auslastung, Storno-Management, Housekeeping, SPA, Restaurant.

Ein Sportverein erhält regelmäßig textbasierte Mitgliederberichte.

Ziel ist ein System, das:

Kennzahlen aus Texten extrahiert (z. B. Mitgliederzahlen, SEPA, Tarife)
diese gegen Regelwerke prüft
automatisch Empfehlungen erzeugt

Bearbeiten Sie:

Welche Kennzahlen sollten aus Berichten extrahiert werden?
Formulieren Sie 3–5 symbolische Regeln (Beitrag, SEPA, Nachweise).
Warum ist eine symbolische Ebene im Vereinskontext wichtig?

Entwerfen Sie ein System aus drei Komponenten:

Neuronale Komponente zur Extraktion aus Texten
Symbolisches Regelwerk (Beiträge, Compliance, Verwaltung)
Pipeline: Bericht → LLM → Fakten → Regeln → Empfehlung

Diskutieren Sie:

Vorteile für einen Sportverein (Automatisierung, Konsistenz, Transparenz).
Risiken (Fehler in Extraktion, Regelkollisionen, Datenqualität).
Wo könnte der Verein ein solches System direkt einsetzen?

Verkaufsstatistiken

Ein Unternehmen analysiert wöchentlich Verkaufsstatistiken. Nun soll ein neuro-symbolisches System entwickelt werden:

Extraktion von Kennzahlen aus Textberichten

Prüfung gegen KPI-Regeln

Generierung von Handlungsempfehlungen

Beantworten Sie:

Welche Kennzahlen können extrahiert werden?

Formulieren Sie 3–4 KPI-Regeln.

Warum reicht ein rein neuronales System nicht aus?

Entwerfen Sie ein System bestehend aus:

Neuronaler Komponente zur Informationsextraktion

Symbolischem Regelwerk

Pipeline: Input → LLM → Fakten → Regeln → Empfehlung

Beantworten Sie:

Vorteile von Neuro-Symbolischer KI

Herausforderungen der Integration

Einsatz in BI-Dashboards