Big Data & Data Science
Data Exploration

WS 2025/26

Prof. Dr. Klemens Waldhör

Interviewer: What's your biggest strength?

Me: I'm an expert in machine learning.

Interviewer: What's 9 + 10?

Me: Its 3.

Interviewer: Not even close. It's 19.

Me: It's 16.

Interviewer: Wrong. Its still 19.

Me: It's 18.

Interviewer: No, it's 19.

Me: it's 19.

Interviewer: You're hired

1. Data Science Process CRISP-DM

Data Science Process – Schritte

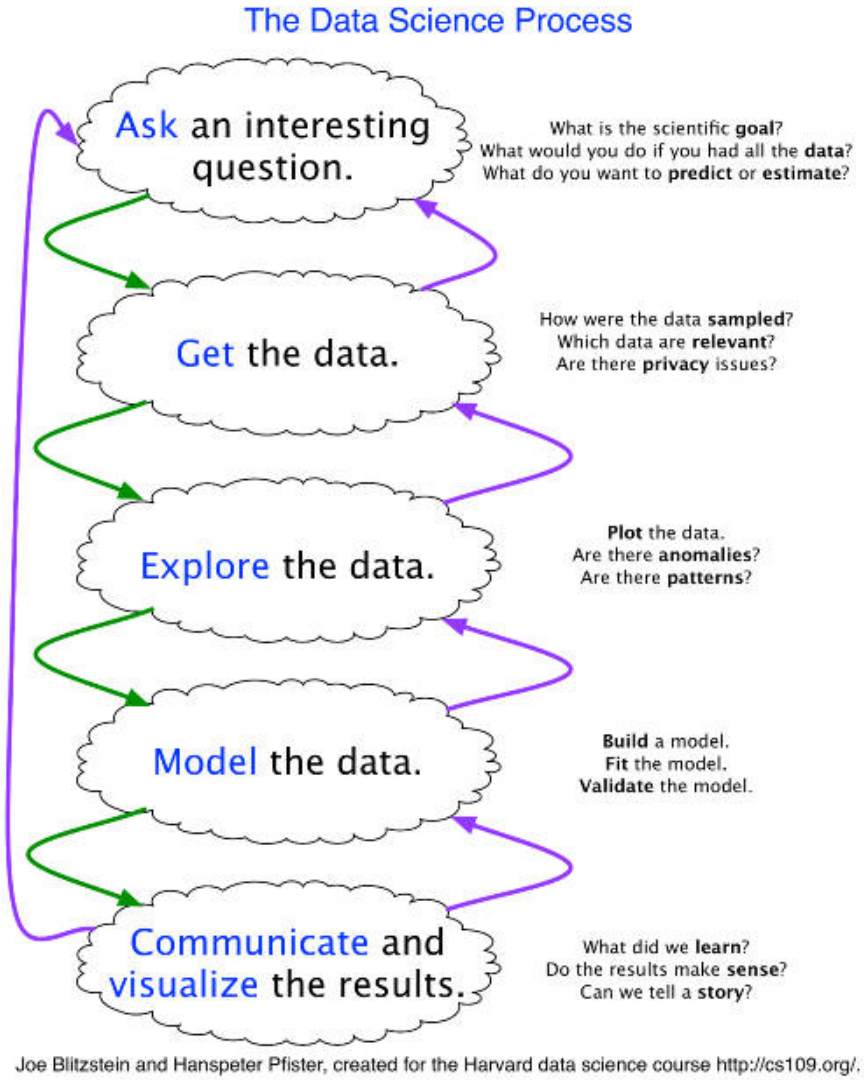

Data Science Process – Beispiel ADL Erkennung

Ist es möglich Trinkbewegungen mit Hilfe von Smartwatch Inertialsensoren von anderen Bewegungen des täglichen Lebens (ADLs) zu unterscheiden?

Motivation:

- Exsikkose (Flüssigkeitsmangel) ist insbesondere bei älteren Menschen stark verbreitet
- Eine der Hauptursachen ist die Dehydration bedingt durch Adipsie (vermindertes Durstgefühl)
- Die Stationäre Behandlung von Exsikkose Patienten verursacht massive Kosten
- Dehydrationsprävention und Therapie von Adipsie können helfen die Kosten zu senken

Idee:

- Smartwatch als passive Ambient Assisted Living (AAL) Plattform im Alltag
- Detektion von Anomalien in der Flüssigkeitsaufnahme (Häufigkeit, Frequenz, usw.) durch Bewegungserkennung
- Hinweis an Anwender bei zu geringer Flüssigkeitsaufnahme

Data Science Process – Beispiel ADL Erkennung

Datensatz

- 1200 Bewegungen
  - 300 Trinkbewegungen
  - 900 sonstige Bewegungen
- Aufgezeichnet mit 28 Testpersonen

Eine Bewegung wird repräsentiert durch

- 10 Sekunden Intervall
- 1800 Messwert-Tripel
- 1 CSV Datei

$\vec{\omega}$ Winkelrotation
Gyroskop
Abtastrate: 100 Hz

$\vec{a}$ Beschleunigung
Accelerometer
Abtastrate: 65 Hz

$\vec{B}$ Magnet. Flussdichte
Magnetometer
Abtastrate: 15 Hz

Data Science Process – Beispiel ADL Erkennung

Explore the data.

```
-5;-1;1420537162191;WEAR;SmartWatch 3
-5;-2;1420537162191;TEXT;Trinken
0;1;1420537162281;WA;0.22500217;-4.495256;8.478273
0;2;1420537162288;WA;0.22500217;-4.437809;8.305931
0;3;1420537162304;WA;0.12925656;-4.8973875;8.305931
0;4;1420537162314;WG;-0.005326745;0.0;-0.018643608
0;5;1420537162318;WA;0.30159867;-4.5144053;8.612317
…
0;16;1420537162368;WG;-0.039950587;0.0026633726;-0.029297099
0;17;1420537162369;WA;0.32074776;-4.5527034;8.439975
0;18;1420537162374;WG;0.031960472;0.069247685;-0.5619716
0;19;1420537162387;WA;0.22500217;-4.5718527;8.056993
0;21;1420537162387;WG;0.045277335;0.07191106;-0.5619716
0;22;1420537162398;WG;0.058594197;0.07191106;-0.56729835
```

Example raw data retrieved from the smartwatch

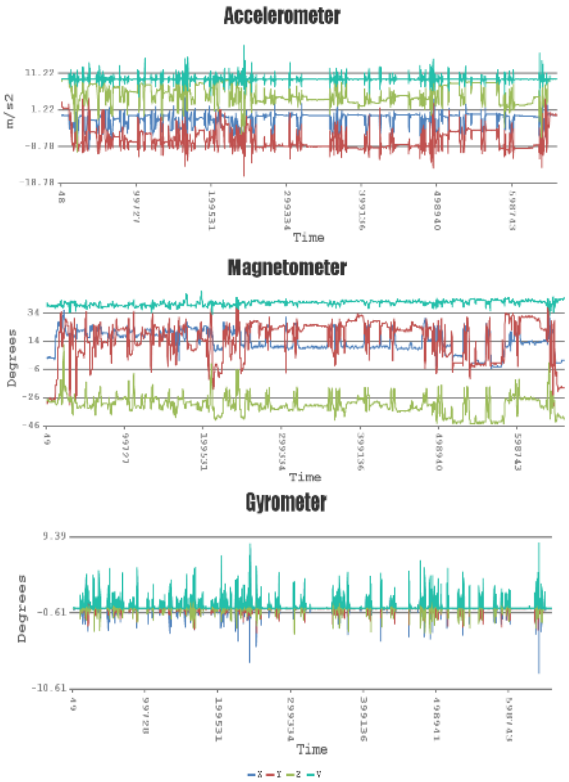

Data Science Process – Beispiel ADL Erkennung

Explore the data.

- Ausgangssignal

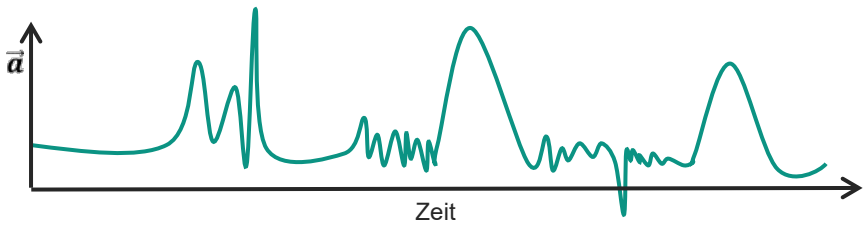

- Median- und Tiefpassfilter (nur Frequenzen >5Hz sind relevant für Bewegungsklassifikation)

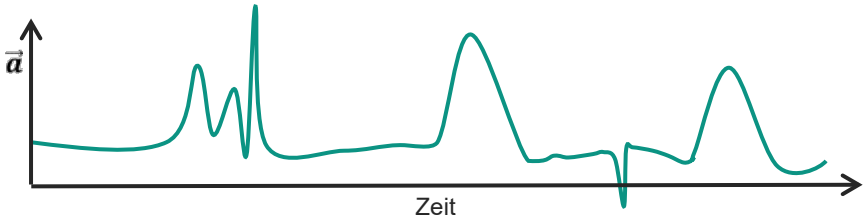

- Extraktion relevanter zeit- und frequenzbezogener Merkmale

Merkmalsdatensätze
(X_{TIME}, X_{FREQ}, X_{ALL})

Data Science Process – Beispiel ADL Erkennung

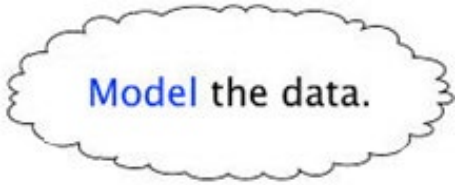

Merkmals-datensätze (X_{TIME}, X_{FREQ}, X_{ALL})

Modelle:
- Logistische Regression
- Entscheidungsbaumklassifikation
- Random Forest
- Neuronale Netze

Ausgangs-daten

66% → Trainings-daten → **Modell trainieren** → **Modell validieren** → Ergebnisse

34% → Testdaten → **Modell validieren**

Data Science Process – Beispiel ADL Erkennung

		Durchgeführte Bewegung	
		Trinkbewegung	Nicht-Trinkbewegung
Klassifizierte Bewegung	Trink-bewegung	30 (96,7 %)	12 (16,2 %)
	Nicht-Trinkbewegung	1 (3,3 %)	62 (83,8 %)

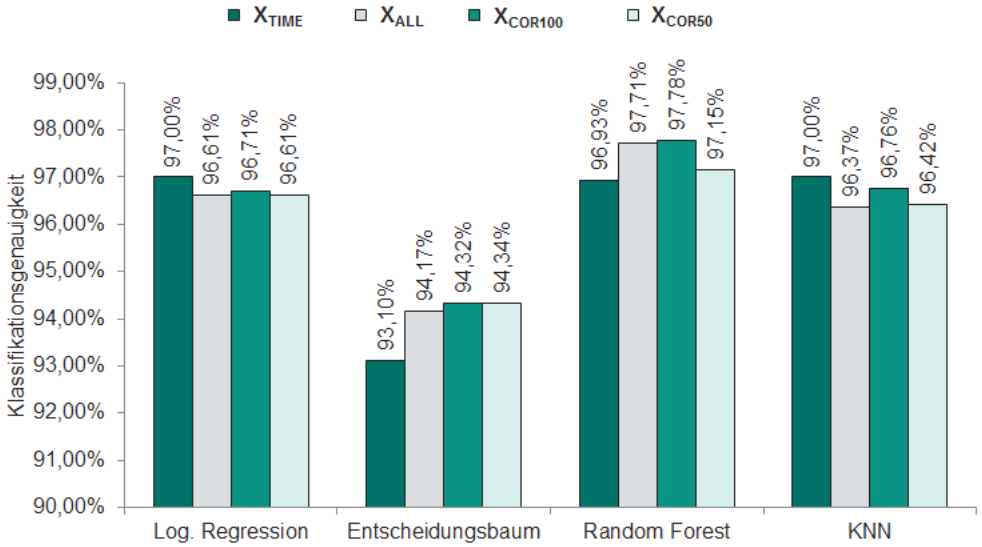

Data Science Process – Beispiel ADL Erkennung

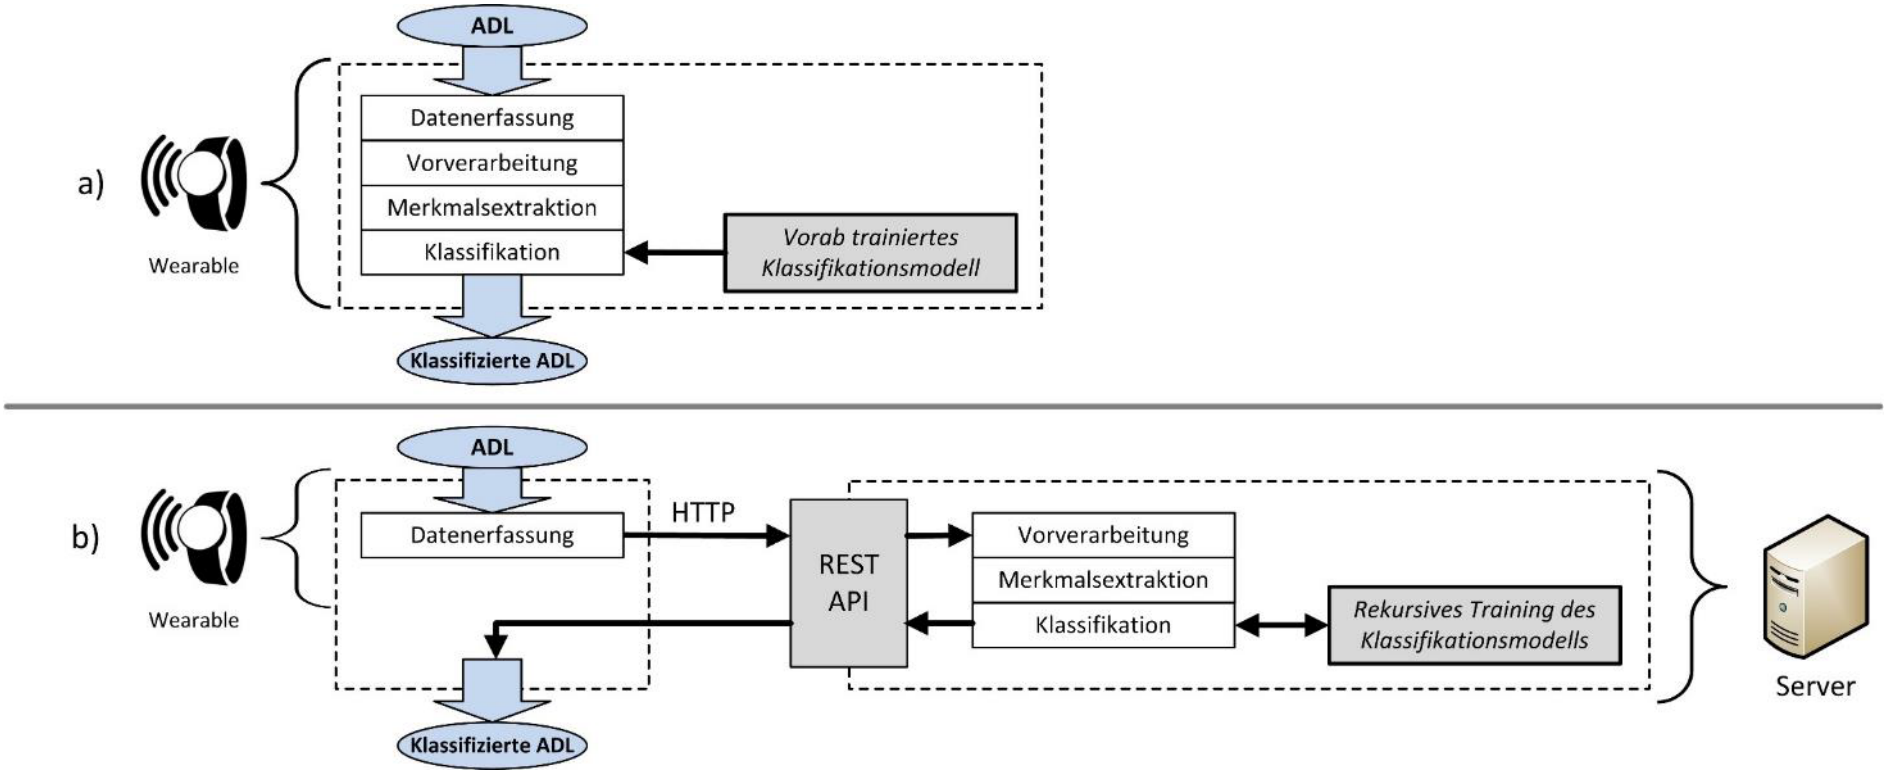

Baldauf R (2015) Mobile sensorbasierte Erkennung von Trinkbewegungen. Thesis, Nürnberg.
Waldhör K, Baldauf R (2015) Recognizing Drinking ADLs in Real Time using Smartwatches and Data Mining. In: Fischer S, Mierswa I, Schäfer G (Hrsg.) Proceedings of the RapidMiner Wisdom Europe (2015), RapidMiner, Aachen.

Data Mining Process Model: CRISP-DM

CRoss-Industry Standard Process for Data Mining

1. Verstehen der Aufgabe

- Ist-Zustand, Soll-Zustand
- Risiken, Kosten, Nutzen

2. Verständnis der Daten

- Welche Daten
- Verfügbarkeit, Bedeutung, Beschreibung

3. Datenvorbereitung

- Selektieren, Datentabellen
- Säuberung, fehlende Werte, Korrektur

4. Data Mining

- Datenanalyse, Modell erstellen

5. Evaluation

- Ergebnisse überprüfen
- Erfolgskriterien

6. Einsatz im Unternehmen

- Überführung in den betrieblichen Einsatz
- Prognose, Wartung, Modellpflege

Data Mining Process Model - Schritte [CL]

1. Selektion

- Bestimmen der geeigneten Daten
- Einbinden externer Datensätze
- Beachten technischer oder rechtlicher Restriktionen
- Entwicklung von Alternativen

2. Datenvorverarbeitung

- Qualität des Datenmaterials prüfen
- Behandlung fehlender Werte
- Ausreißererkennung
- Fehlerhafte Daten erkennen und korrigieren

3. Transformation

- Umwandeln der Rohdaten in adäquates Format
- Codierung von offenen Texten
- Normalisierung/ Standardisierung
- Dimensionsreduktion

4. Data Mining - Suche nach Mustern

- Auswahl des Verfahrens
- Parametrisierung
- Erzeugen und Testen von Modellen

5. Interpretation und Evaluierung

- Aufgedeckte Muster und Beziehungen bewerten und interpretieren
- Ergebnisse aufbereiten -> Anforderungen:
  - Gültigkeit
  - Neuartigkeit
  - Verständlichkeit
  - Nützlichkeit

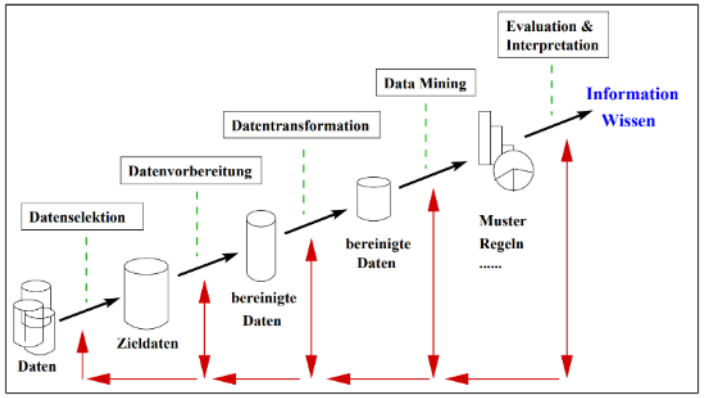

2. Data Science Platforms

Big Data Landscape 2020

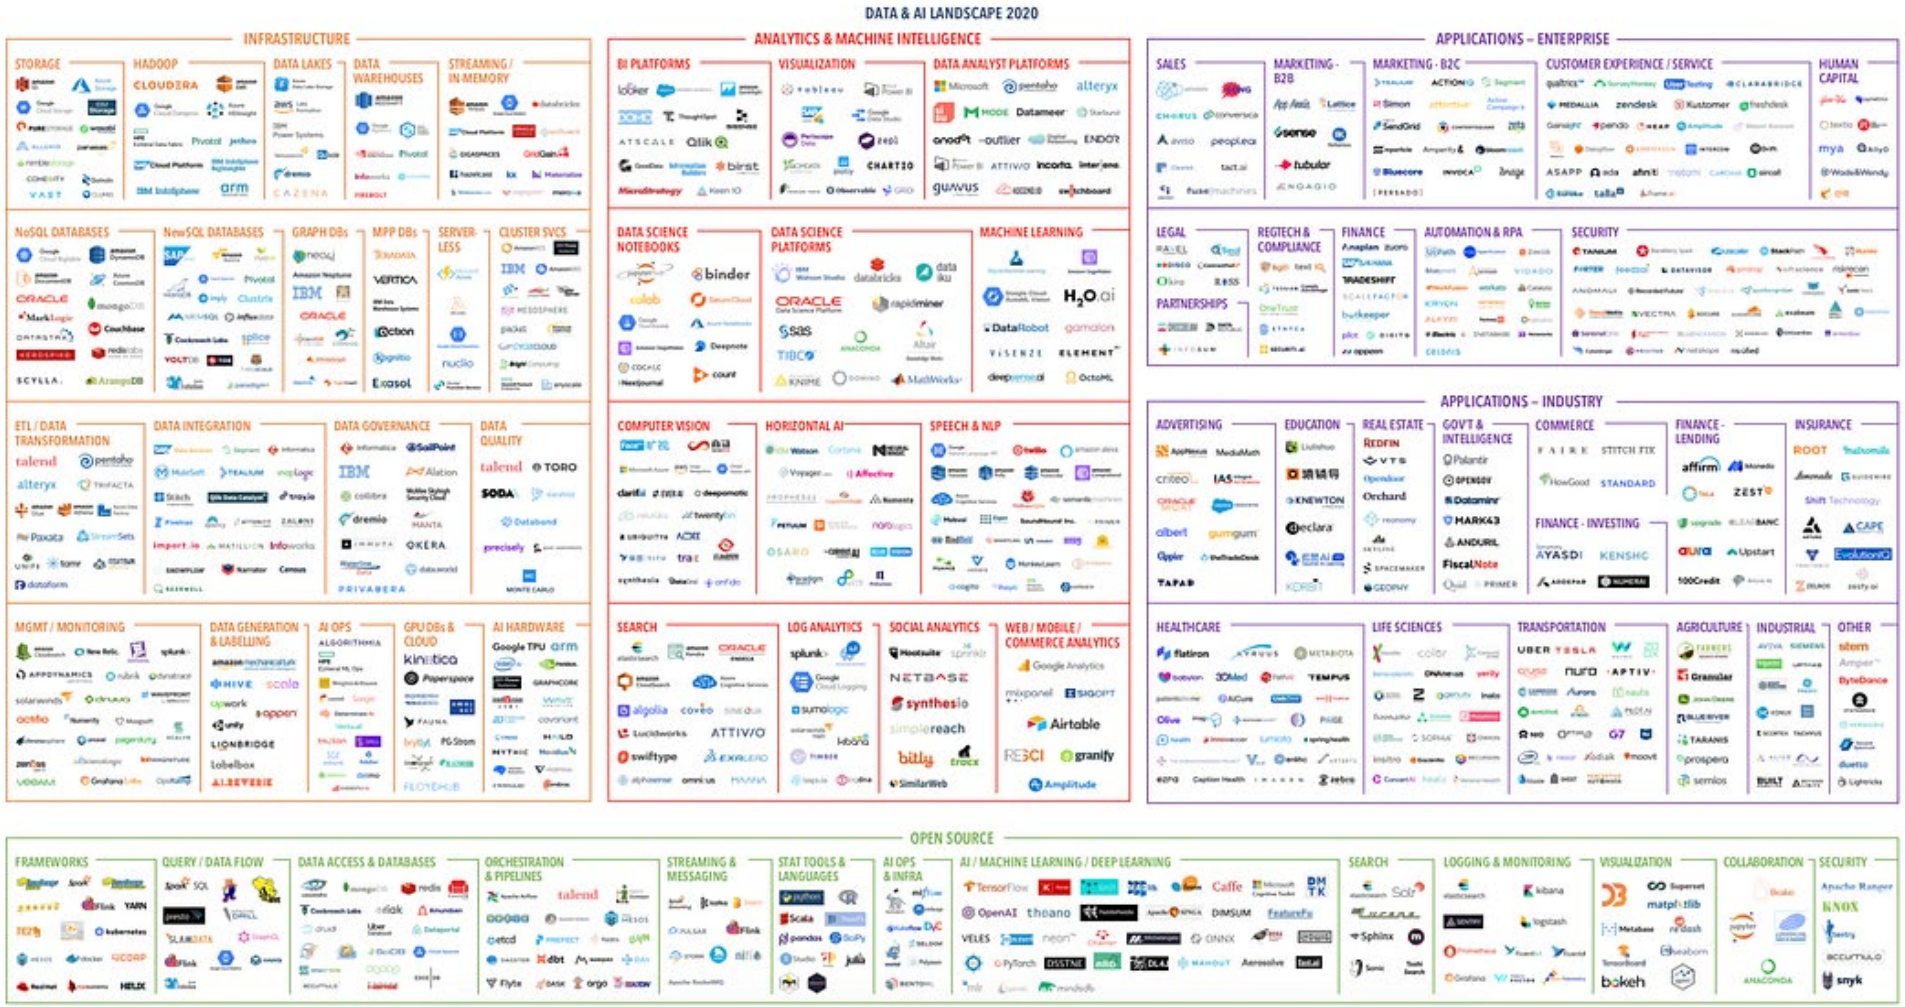

Data Science Platforms

- Gartner Magic Quadrants for Data Science Platforms 2025

  https://cloud.google.com/blog/products/ai-machine-learning/gartner-2025-magic-quadrant-for-data-science-and-ml-platforms?hl=en

Figure 1: Magic Quadrant for Data Science and Machine Learning Platforms

(https://www.kdnugget
science-platforms-gaine

Gartner

Plattformen

End-to-End Cloud-Plattformen

AWS SageMaker

- Studio/Notebooks, Training, Deployment, Governance

Google Vertex AI

- Training/Serving, Vektor-/Feature-Dienste, Agent Builder

Azure Machine Learning

- MLOps, Registry, Responsible-AI-Guides

Databricks (Lakehouse)

- Spark/Delta/MLflow nativ, Unified Data+AI

Snowflake (Cortex/AISQL)

- LLM nahe an Daten, sichere Ausführung im Warehouse

Kollaborative DS-Studios (Low/No-Code + Code)

Dataiku

- Visuelle Flows + Code, Governance

Altair RapidMiner

- Visuelle Workflows, AutoML/GenAI

KNIME

- Open-Source, viele Konnektoren, Deployment

H2O Driverless AI

- AutoML, Feature-Engineering, Tuning/Stacking

Plattformen

Open-Source-Bausteine (Eigenbetrieb/On-Prem)

MLflow

- Tracking, Model Registry, Serving

Kubeflow

- K8s-native Orchestrierung, Pipelines/Trainer

Feast

- Feature Store (offline/online)

Apache Airflow

- DAG-basierte Orchestrierung für Data/ML

4) Daten-/Analyse-Basis

Lakehouse/Warehouse

- Databricks (Delta Lake), Snowflake

Native AI/LLM-Funktionen oder enge ML-Integration

Gängige Werkzeuge

- Ein kurzer Überblick über drei häufig verwendete Data Science Plattformen

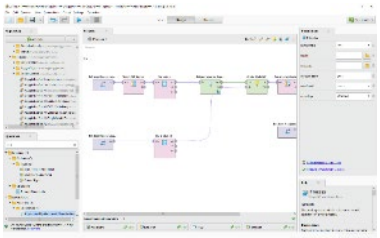

RAPIDMINER

- Drag & Drop Bedienung
- Best „Look and Feel“
- Kostenlose Version vorhanden
- Sehr großer Funktionsumfang
- Kostenlos erweiterbar über Marketplace / Skripte
- Kostenpflichtige Version mit Hadoop/Spark Integration (ab 2500$/Jahr)

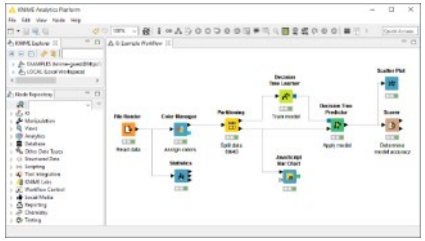

(https://www.knime.org/knime-analytics-platform)

KNIME

- Drag & Drop Bedienung
- Open Source (GNU License)
- Sehr großer Funktionsumfang
- Stark bei Datenvorverarbeitung, Business Intelligence, Analyse von Finanzdaten

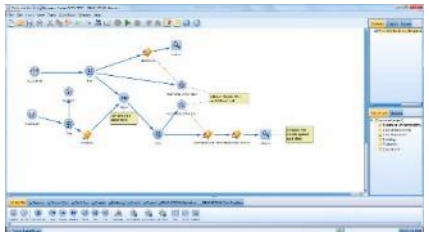

(https://www.ibm.com/de-de/marketplace/spss-modeler)

IBM SPSS

- Drag & Drop Bedienung
- Marktführer
- Stark verbreitet im Bereich Forschung (insbesondere außerhalb der Informatik)
- Speziell geeignet für angewandte Statistik
- Kosten (pro User/Jahr):
  - Basisversion (ca. 1200€)
  - Premium (ca. 8000€)

3. Überblick Altair RapidMiner

RapidMiner

- Webseite Altair

„Altair RapidMiner is a powerful data analytics and AI platform that connects siloed data, unlocks hidden insights, and accelerates innovation with advanced analytics and AI-driven automation.

Flexible and scalable, it empowers organizations to modernize their existing systems while embracing next-generation technologies like generative AI (genAI) and AI agents. “

RapidMiner - Oberfläche

Modell ausführen

Ergebnisanzeige

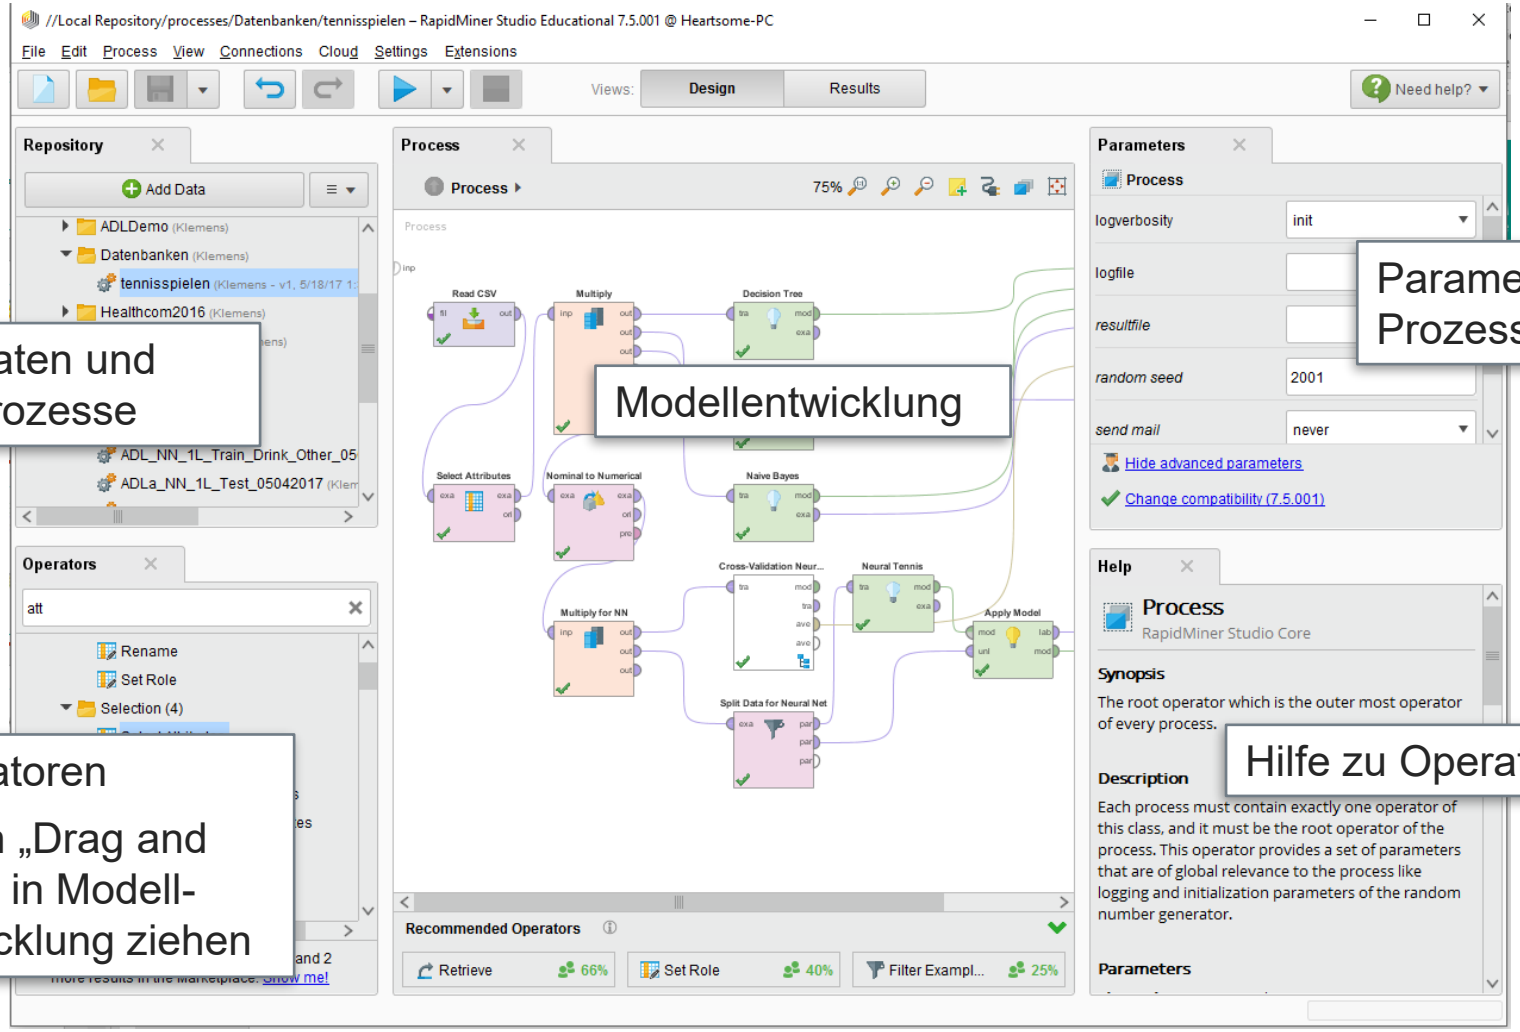

Daten und Prozesse

Modellentwicklung

Parameter für Prozess

Operatoren

Durch „Drag and Drop“ in Modell-entwicklung ziehen

Hilfe zu Operatoren

RapidMiner Prozess – Beispiel ADL Erkennung

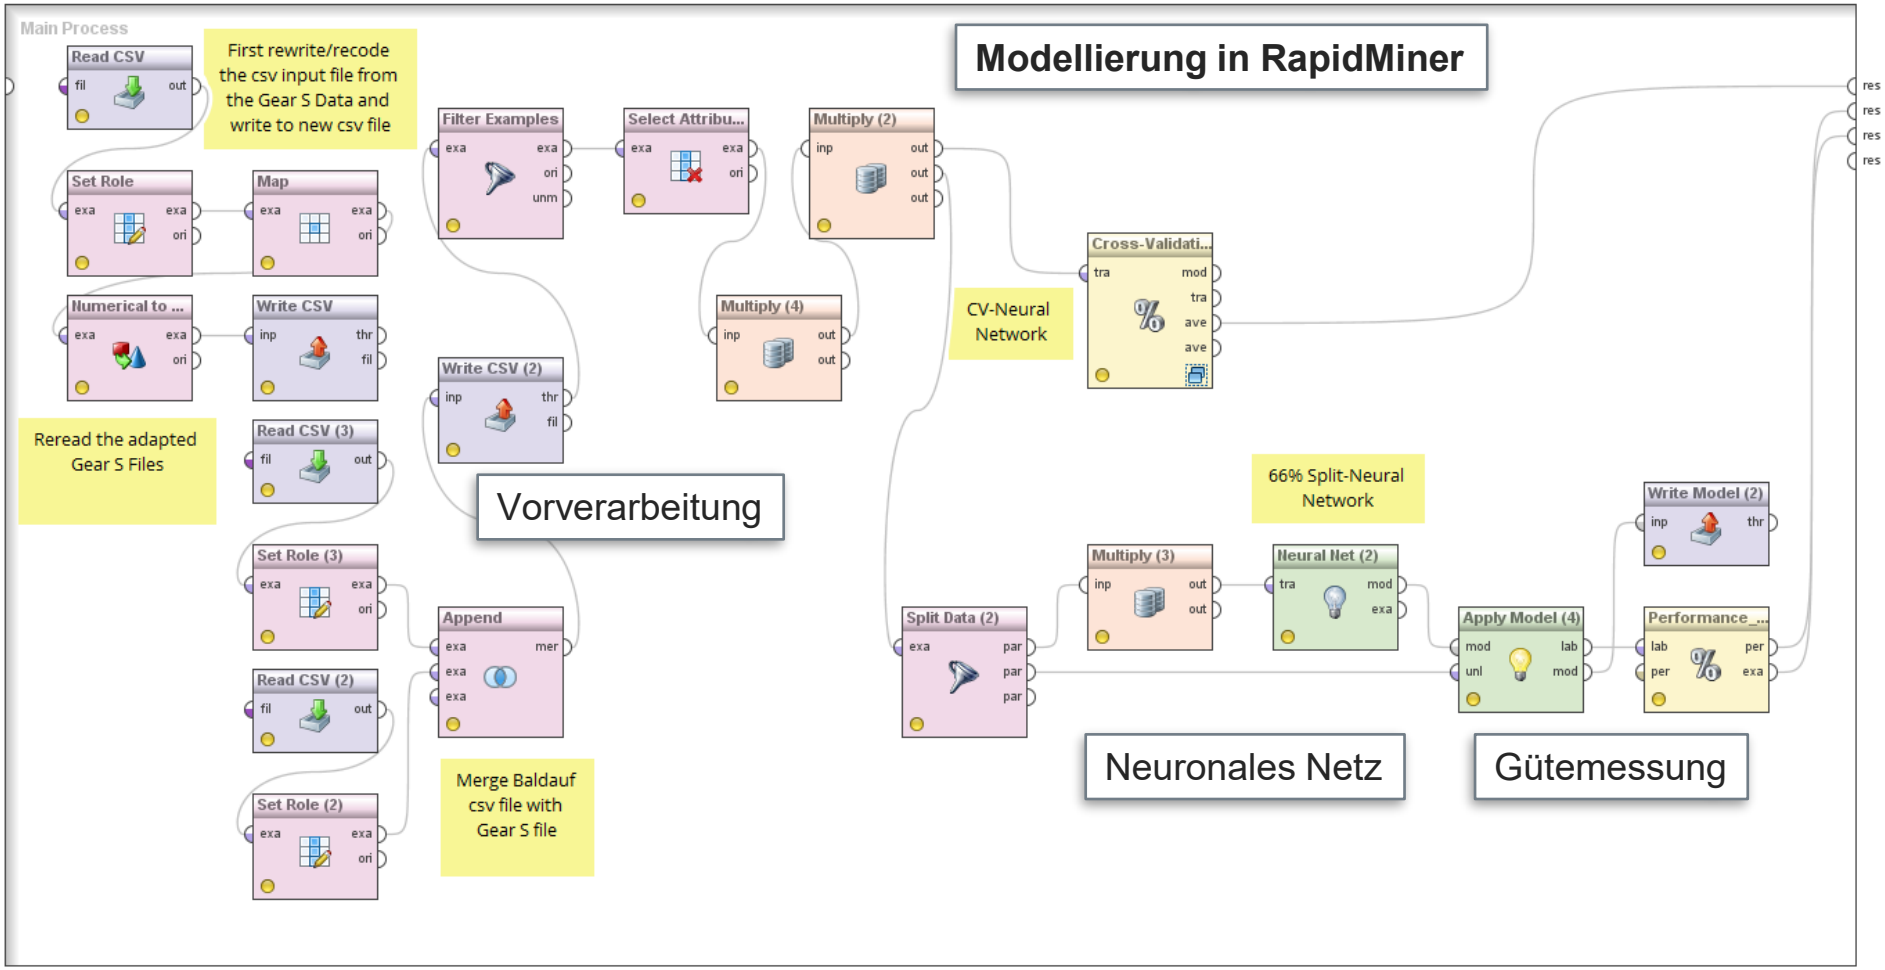

4. Data Exploration

Data Exploration

- Sichtung und Beurteilung der Datenbasis anhand qualitativer und quantitativer Kriterien
- Schafft besseres Verständnis für den zugrundeliegenden Business Case und die damit verbundenen Anforderungen
- Entscheidungsgrundlage für die Auswahl der weiteren Datenverarbeitungs- und Modellierungsmethoden
- Identifikation und Beseitigung von Fehlern und Problemen im Datensatz
- Untersuchung der grundsätzlichen Eignung des Datensatzes für die Problemstellung

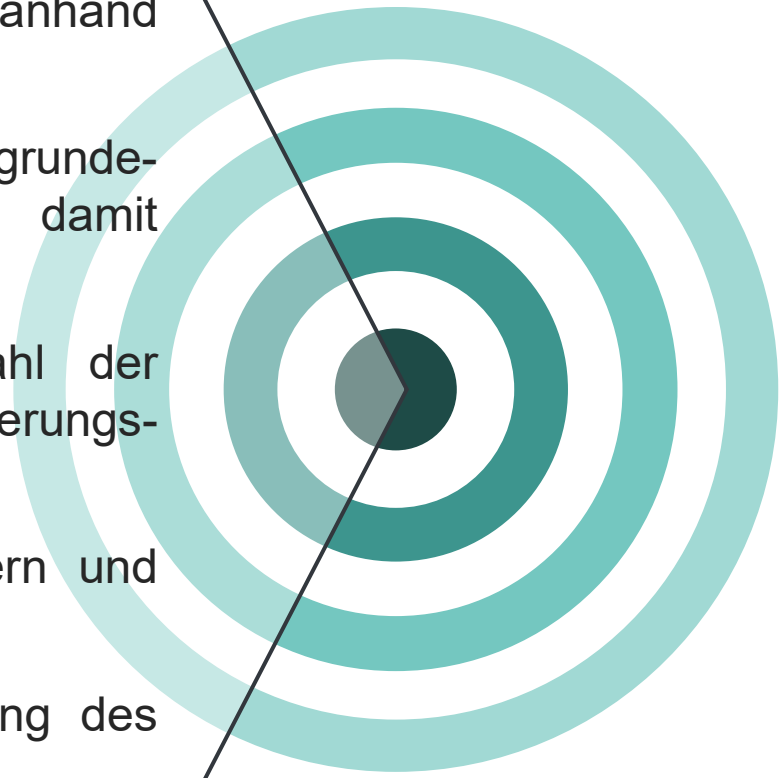

Teilbereiche

Data Exploration

- Visualisierung univariater und multivariater Daten
- Methoden der Deskriptiven Statistik (Univariat/Multivariat)
- Ausreißererkennung
- Umgang mit fehlerhaften Daten und „Missing Values“
- Reduktion der Dimensionalität
- Merkmalsselektion

5. Datenvisualisierung und -analyse (Univariat)

Wiederholung - Statistische Grundlagen - Maßskalen

- Merkmale eines Datensatzes unterscheiden sich hinsichtlich ihrer Skalierung
- Art und Skalierung der Merkmale entscheidet über die Möglichkeiten zur weiteren Verarbeitung und Analyse

Art	Skala	Beschreibung	Beispiel	Zulässige Operationen
Qualitativ	**Nominal**	Keine Rangordnung	Namen (Müller, Meier, Schulze,…)	$=, \neq$
	Ordinal	Rangordnung, Abstände nicht interpretierbar	Schulnoten (sehr gut, gut, befriedigend,…)	$=, \neq, <, >$
Quantitativ	**Metrisch diskret**	Rangordnung, Abstände interpretierbar, Abzählbar (endlich oder unendlich), Ganze Zahlen $\mathbb{Z}$	Alter in Jahren	$=, \neq, <, >, +, -, ., /$
	Metrisch stetig	Rangordnung, Abstände interpretierbar, Nicht-Abzählbar, Reelle Zahlen $\mathbb{R}$	Körpergröße	$=, \neq, <, >, +, -, ., /$

(Runkler,TA 2010)

Wiederholung - Statistische Grundlagen - Maßskalen

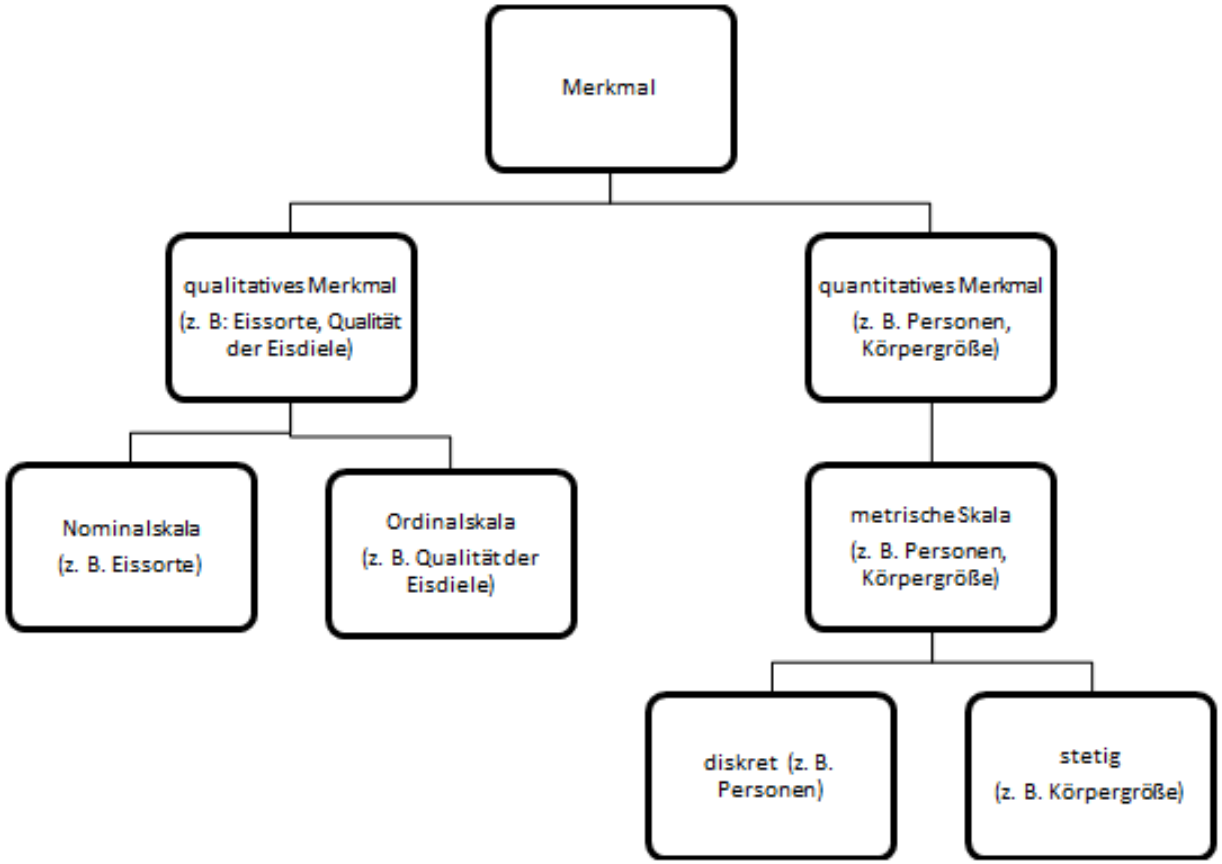

(https://wiki.zum.de, 2017)

Wiederholung – Lage und Streuungsparameter

- Lage und Streuungsparameter bieten eine numerische Repräsentation der Häufigkeitsverteilung einzelner Variablen
- Lageparameter:

  Modus, Median, Arithmetisches Mittel

  Liefern Informationen über die zentrale Tendenz einer Verteilung

  Sind nur sinnvoll, wenn tatsächlich eine zentrale Tendenz der Daten vorliegt (Messbar durch Streuungsparameter)
- Streuungsparameter:

  Spannweite, Stichprobenvarianz, Standardabweichung

  Beschreiben die Homogenität einer Verteilung

  Je homogener die Verteilung ist, desto geringer fällt die Streuung der Messwerte um die Lagerparameter aus

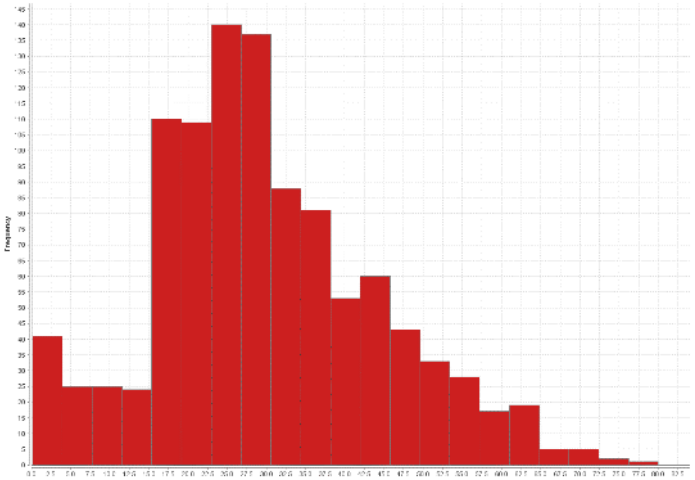

Histogramm der Altersverteilung

Wiederholung - Lageparameter

Modus

- Häufigste Merkmalsausprägung
- Anwendbar auf nominal, ordinal und metrisch skalierte Daten

$$\bar{x}_M = max_i \; n_i$$

Arithmetisches Mittel

- Mittelwert
- Empfindlich gegenüber Ausreißern
- Anwendbar auf metrisch skalierte Daten

$$\bar{x} = \frac{1}{n}\sum_{i=1}^{n} x_i$$

Median

- Mittlerer Datenpunkt des Datensatzes (bzw. Arithmetisches Mittel der beiden mittleren Datenpunkte)
- Erfordert aufsteigende Sortierung der Daten
- Robust gegenüber Ausreißern
- Anwendbar auf ordinal und metrisch skalierte Daten

$$\tilde{x} = \begin{cases} x_{\frac{n+1}{2}} & n\,ungerade \\ \frac{1}{2}\left(x_{\frac{n+1}{2}} + x_{\frac{n}{2}+1}\right) & n\,gerade \end{cases}$$

(Runkler,TA 2010)

Wiederholung – Lageparameter

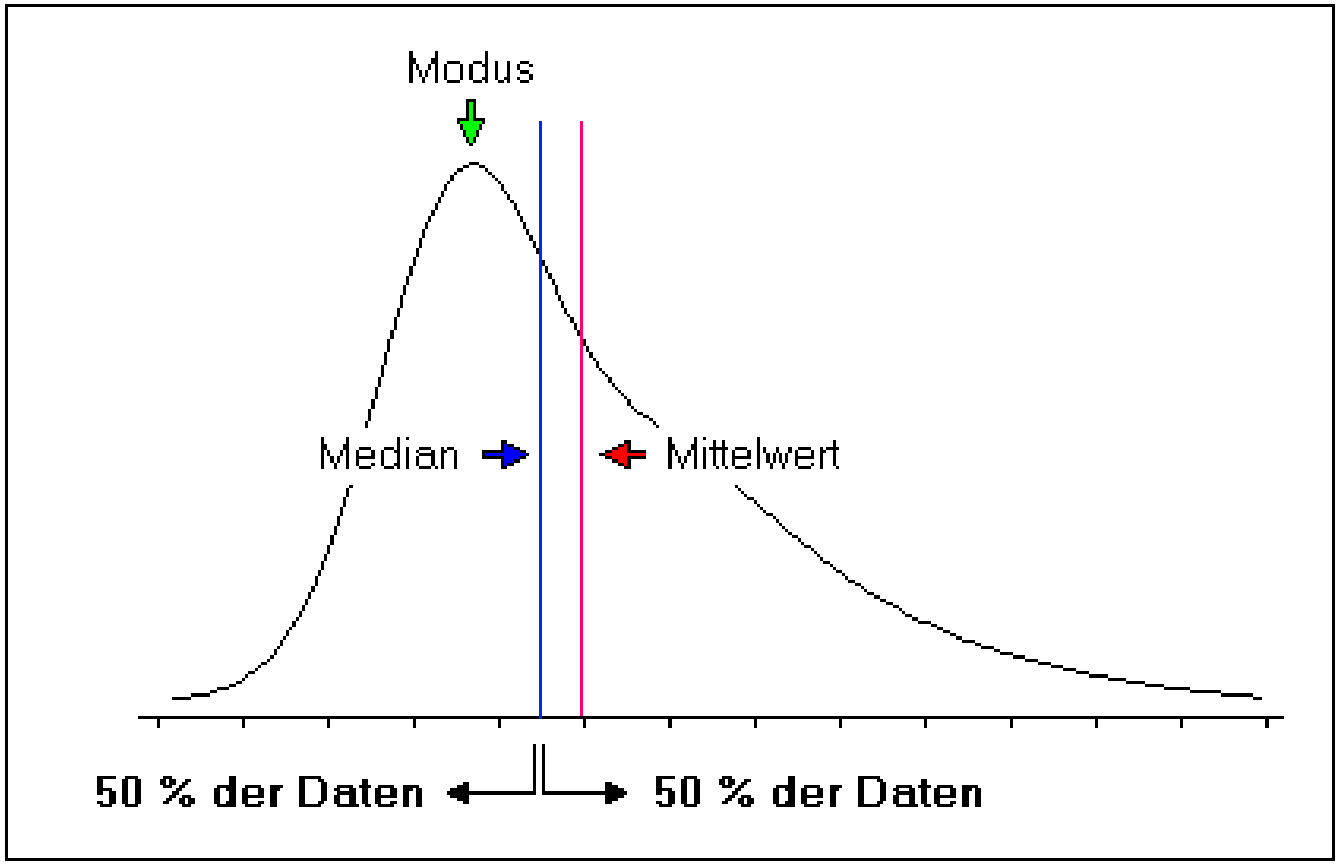

(www.statistics4u.info , 2017)

Wiederholung – Lageparameter – Schiefe der Verteilung

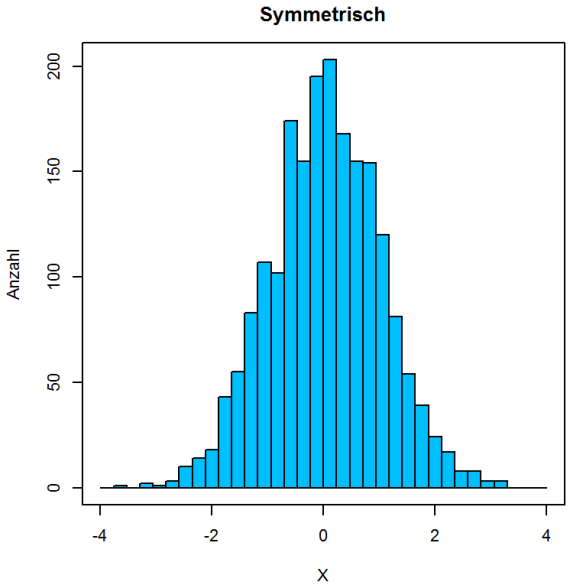

$$x_{\text{mod}} = x_{\text{med}} = \overline{x}$$

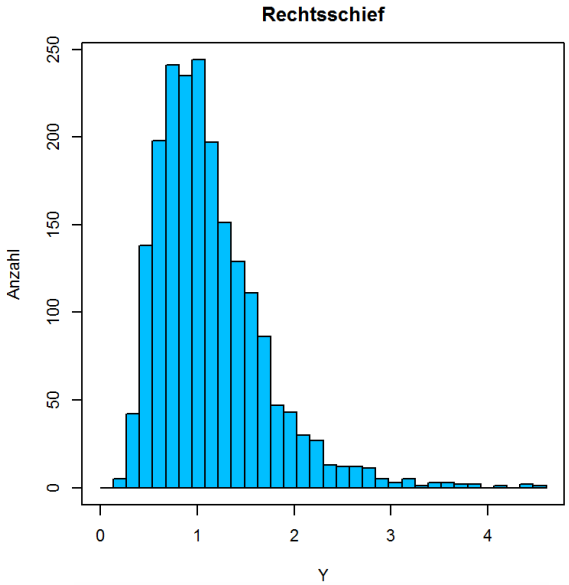

$$x_{\text{mod}} < x_{\text{med}} < \overline{x}$$

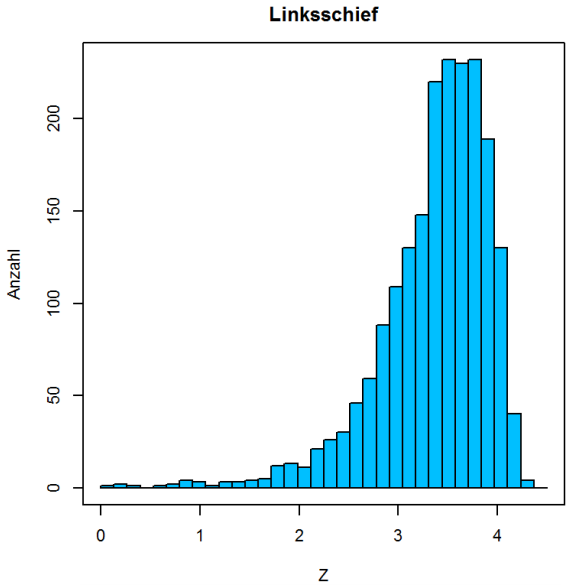

$$x_{\text{mod}} > x_{\text{med}} > \overline{x}$$

(https://www.beratung-statistik.de/statistik-beratung-infos/r-tutorial/deskriptive-statistik-r/ , 2017)

Wiederholung - Streuungsparameter

Spannweite

- Differenz zwischen Maximum und Minimum
- Anfällig gegenüber Ausreißern
- Anwendbar auf metrisch skalierte Daten

$$R = x_{max} - x_{min}$$

Stichprobenvarianz

- Mittlere quadratische Abweichung vom Mittelwert

$$\sigma^2 = \frac{1}{n-1}\sum_{i=1}^{n}(x_i - \bar{x})^2$$

Standardabweichung

- Durchschnittliche Abweichung vom Arithmetischen Mittel

$$\sigma = \sqrt{\sigma^2}$$

(Runkler,TA 2010)

Wiederholung - Visualisierung Nominal- und Ordinalskalierter Daten

- Direkte Visualisierung qualitativer Daten nicht möglich
- **Aber:** Absolute und relative Häufigkeiten der Daten sind visualisierbar
- Beispiel: Titanic – „Port of embarkation“

Absolute Häufigkeiten n_i

$$n_{Southhampton} = 914$$
$$n_{Cheerbourg} = 270$$
$$n_{Queenstown} = 123$$

Balken -diagramm

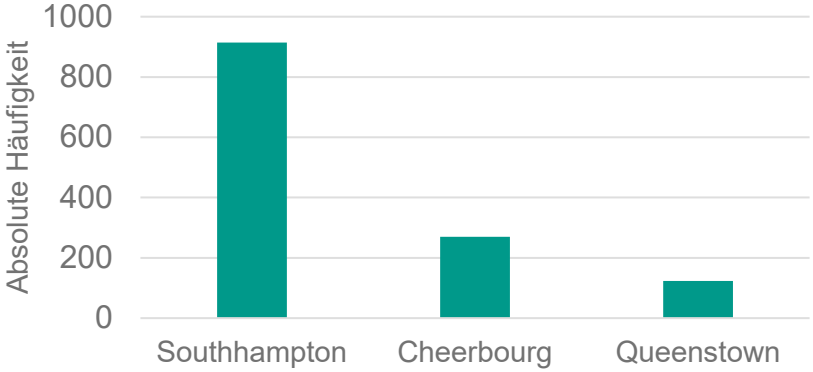

Relative Häufigkeiten f_i

$$f_i = \frac{n_i}{\sum_i n_i}$$

$$f_{Southhampton} = 0.6993$$
$$f_{Cheerbourg} = 0.2066$$
$$f_{Queenstown} = 0.0941$$

Kreis -diagramm

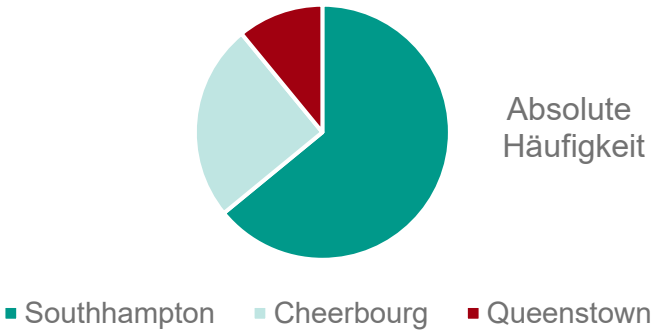

Wiederholung - Visualisierung metrisch-skalierter Daten

- **Histogramm**
  - Visualisierung der Häufigkeitsverteilung metrischer Merkmale
  - Erfordert Klassierung der Daten („Binning“) und Bestimmung der absoluten Klassenhäufigkeiten

Klasse	Häufigkeit
$x \leq 5$	23
$5 < x \leq 10$	12
...	...
$60 < x \leq 65$	7
$x > 65$	3

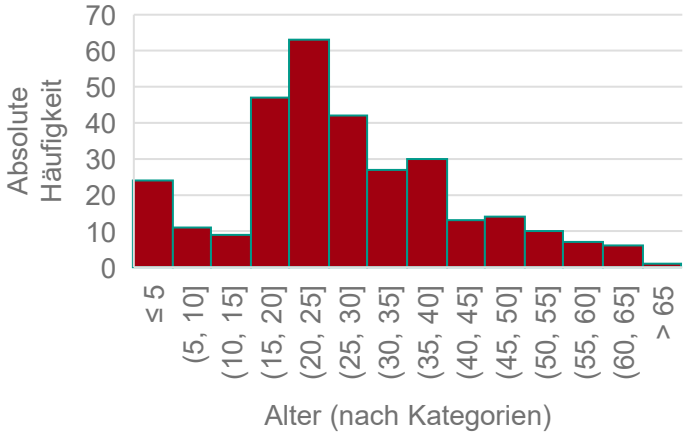

- **Box-Whisker-Plot**
  - Visualisierung der Häufigkeitsverteilung einschließlich wichtiger Lage- und Streuungsparameter
  - Gibt Aufschluss über Verteilung und Schiefe der Daten
  - Ermöglicht die Visualisierung von Ausreißern
  - $IQR = Quartil_{0.75} - Quartil_{0.25}$
  - $min = Quartil_{0.25} - 1.5\,IQR$
  - $max = Quartil_{0.75} + 1.5\,IQR$

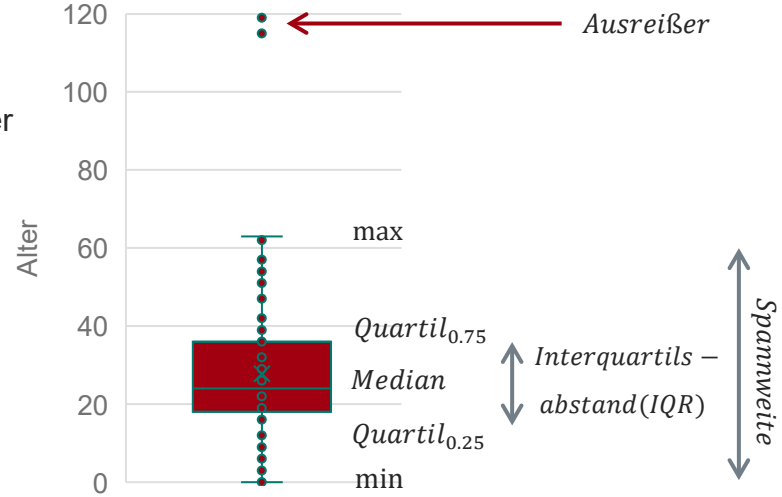

Wiederholung - Normalverteilung

- Viele statistische Verfahren erfordern eine annähernde Normalverteilung stetiger Variablen

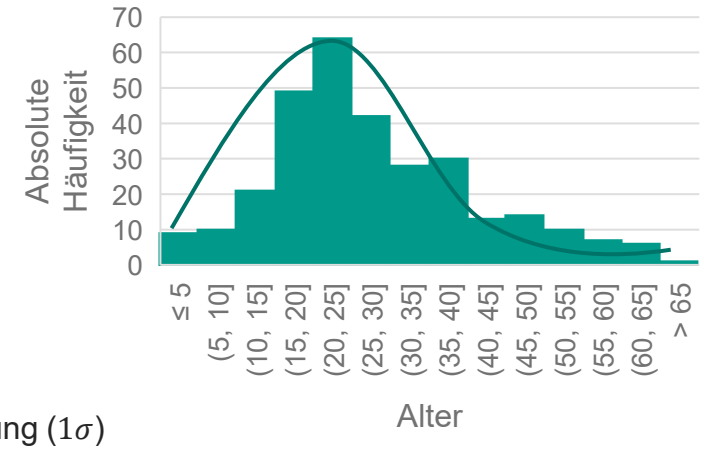

- **Normalverteilung:**

$$f(x) = \frac{1}{\sigma\sqrt{2\pi}} \cdot e^{-\frac{1}{2}\left(\frac{x-\mu}{\sigma}\right)^2}$$

  - symmetrisch ($x_{\text{mod}} = x_{\text{med}} = \overline{x}$)
  - Verteilung der Daten um den Mittelwert:
    - 68% der Daten innerhalb der einfachen Standardabweichung (1σ)
    - 95% der Daten innerhalb der doppelten Standardabweichung (2σ)
    - 97,5% der Daten innerhalb der dreifachen Standardabweichung (3σ)
    - Daten außerhalb von 3σ werden als Ausreißer betrachtet

- Überprüfung auf Normalverteilung durch statistische Tests (χ^2-Test, Kolmogorov-Smirnov-Anpassungstest)

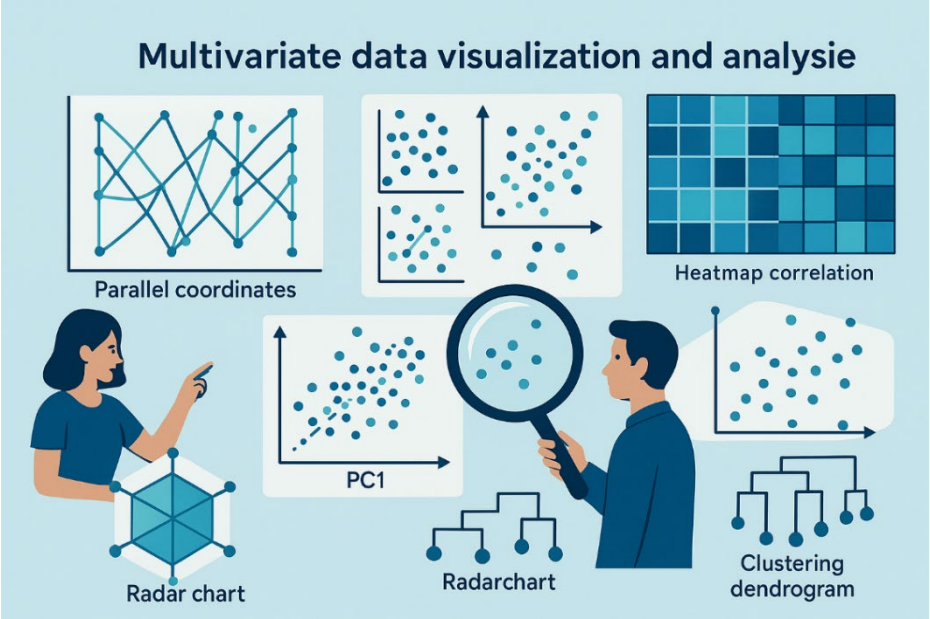

6. Datenvisualisierung und –analyse (Bi-/Multivariat)

Wiederholung - Analyse bi-variater stetiger Merkmale

Stichprobenkovarianz

- Maß für die Richtung des linearen Zusammenhangs zweier metrischer Merkmale

$$s_{xy} = \frac{1}{n-1}\sum_{i=1}^{n}(x_i - \bar{x})(y_i - \bar{y})$$

$s_{xy} = 0$: kein linearer Zusammenhang
$s_{xy} > 0$: positiver Zusammenhang
$s_{xy} < 0$: negativer Zusammenhang

Pearson-Korrelation

- Maß für Richtung und Stärke des linearen Zusammenhangs zweier metrischer Merkmale

$$p_{xy} = \frac{s_{xy}}{\sigma_x \sigma_y}$$

$-1 \leq p_{xy} \leq 1$
$p_{xy} = 0$: unkorreliert
$p_{xy} > 0$: perfekt positive Korrelation
$p_{xy} < 0$: perfekt negative Korrelation

Rangkorrelationskoeffizient nach Spearman

- Maß für den monotonen Zusammenhang zweier ordinalskalierten Merkmale
- Werte x und y werden Ränge r_x, r_y ersetzt

$$r_s = \frac{s_{r_x r_y}}{\sigma_{r_x}\sigma_{r_y}}$$

$-1 \leq r_s \leq 1$
$r_s = 0$: unkorreliert
$r_s > 0$: perfekt positive Korrelation
$\mathrm{r_s} < 0$: perfekt negative Korrelation

Bedeutung von Datenvisualisierung

- **Frage:**

  Macht die Verwendung statistischer Merkmale (Lage-, Streuungsparameter, Korrelation, usw.) für die Analyse der Daten eine vorherige Visualisierung überflüssig?

- **Beispiel:**
  - Anscombe‘s Quartett

x	y
10	8,04
8	6,95
13	7,58
9	8,81
11	8,33
14	9,96
6	7,24
4	4,26
12	10,84
7	4,82
5	5,68

Dataset A

x	y
10	9,14
8	8,14
13	8,74
9	8,77
11	9,26
14	8,1
6	6,13
4	3,1
12	9,13
7	7,26
5	4,74

Dataset B

x	y
10	7,46
8	6,77
13	12,74
9	7,11
11	7,81
14	8,84
6	6,08
4	5,39
12	8,15
7	6,42
5	5,73

Dataset C

x	y
8	6,58
8	5,76
8	7,71
8	8,84
8	8,47
8	7,04
8	5,25
19	12,5
8	5,56
8	7,91
8	6,89

Dataset D

Anscombes Quartett

Metrik	Dataset A	Dataset B	Dataset C	Dataset D
Mittelwert $\bar{x}$	9	9	9	9
Mittelwert $\bar{y}$	7.5	7.5	7.5	7.5
Varianz σ_x^2	11	11	11	11
Varianz σ_y^2	4.125	4.125	4.125	4.125
Korrelation r_{xy}	0.816	0.816	0.816	0.816

- Identische statistische Eigenschaften für alle vier Datensätze
- <u>Problem:</u> Ermittelte Werte sind für drei Datensätze nicht repräsentativ, da entweder keine lineare Korrelation vorliegt (B, D) oder Ausreißer die Metriken beeinflussen (C, D).
- Eine vorherige Visualisierung der Daten hilft derartige Zusammenhänge zu erkennen

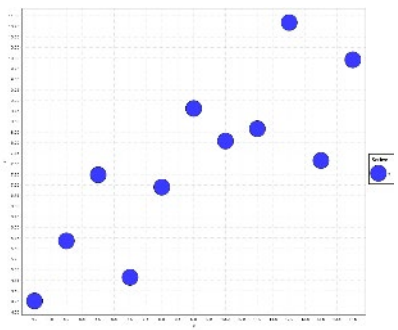

Dataset A

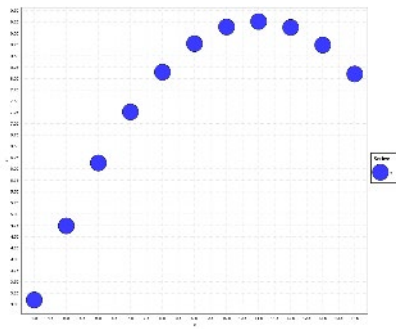

Dataset B

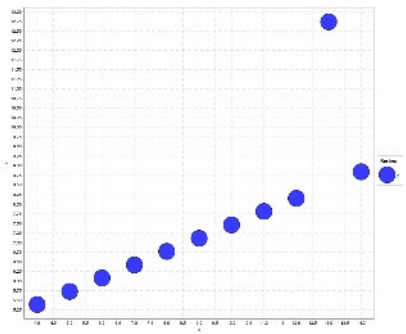

Dataset C

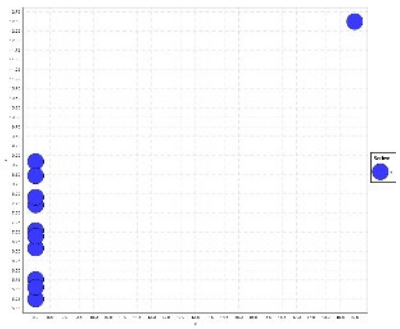

Dataset D

Visualisierung hochdimensionaler Daten

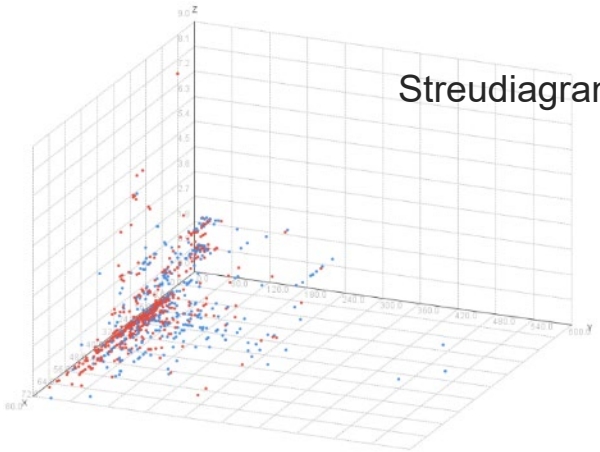

Streudiagramm

Scatterplot mit Farbkodierung (4-D)

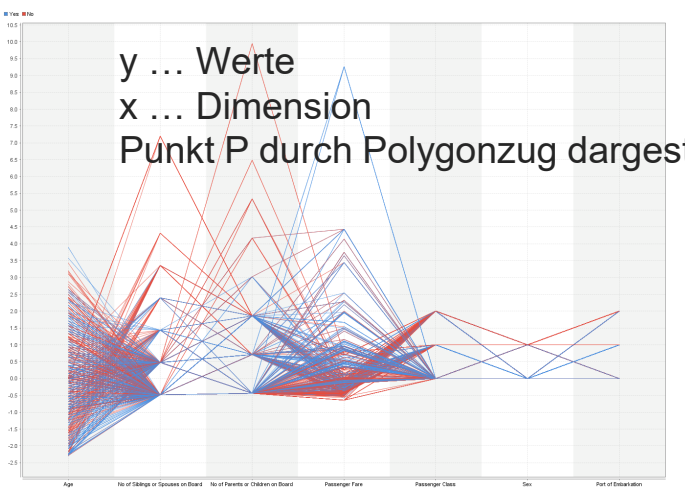

y … Werte
x … Dimension
Punkt P durch Polygonzug dargestellt

Parallel Coordinates (n-D)

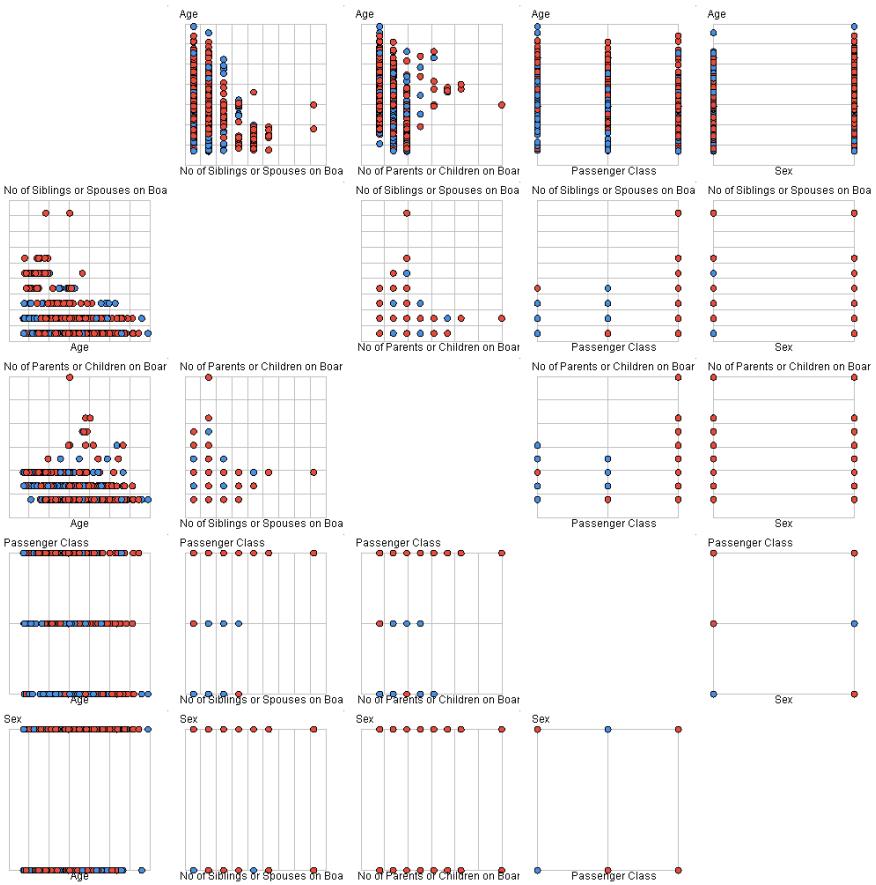

Scatterplot Matrix (n-D)

Streudiagramm-Matrix
Variablen paarweise auftragen

Chernoff Faces: Visualisierung hochdimensionaler Daten

- Visualisierung von Variablen durch Merkmalsausprägungen in Gesichtern (Position, Größe, Abstand)
- Menschliche Fähigkeit zur Gesichtserkennung ermöglicht einfache Interpretation der Daten
- Jede Variable steuert ein Gesichtsmerkmal (z. B. Augenabstand, Mundkrümmung, Nasenlänge, Kopfbreite, Augenbrauenwinkel). Ähnliche Beobachtungen „sehen sich ähnlich“.
- Beispiel Kriminalität USA

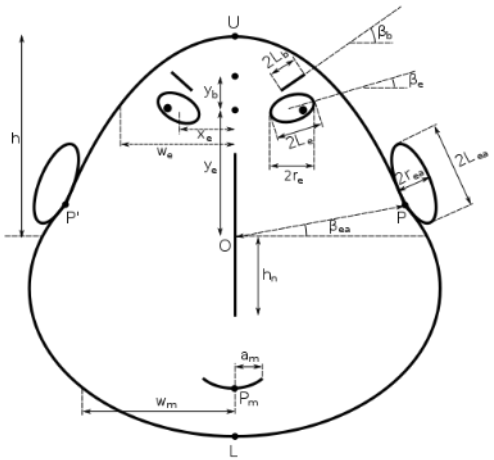

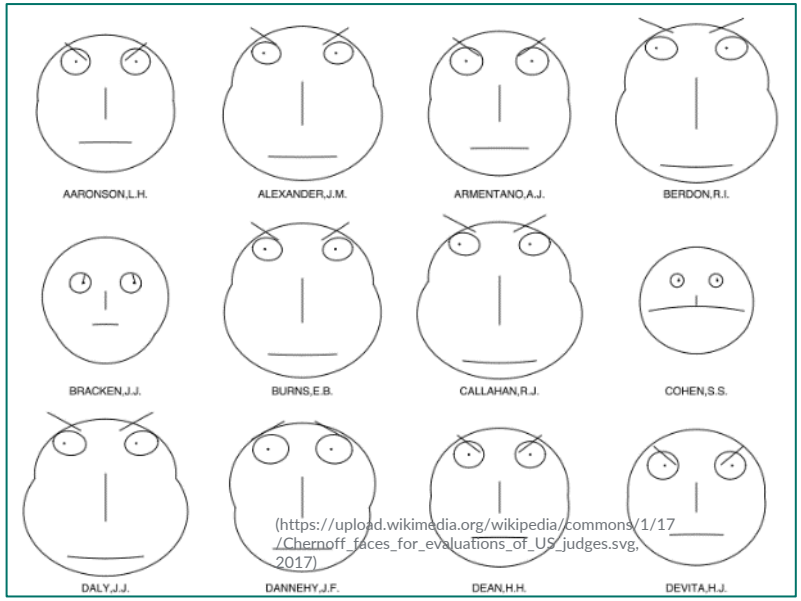

(https://upload.wikimedia.org/wikipedia/commons/1/17/Chernoff_faces_for_evaluations_of_US_judges.svg, 2017)

Chernoff Faces: Visualisierung hochdimensionaler Daten

Beispiel Kriminalität USA

- Stimmung/Performance → Mundkrümmung (↓ schlecht … ↑ gut)
- Risiko/Varianz → Augenöffnung (klein … groß)
- Größe/Skalierung → Gesichtsbreite
- Symmetrie/Balance → Augenbrauenwinkel
- Kategorie → Haar-/Randfarbe (sparsam einsetzen)

Vorteile / Nachteile

- ✅ Extrem intuitive Gestaltwahrnehmung, viele Variablen pro Objekt.
- ⚠️ Subjektiv; unterschiedliche Merkmale wirken unterschiedlich stark (Mund & Augen dominieren).
- ⚠️ Für präzise Vergleiche ungeeignet; eher qualitativ als quantitativ.

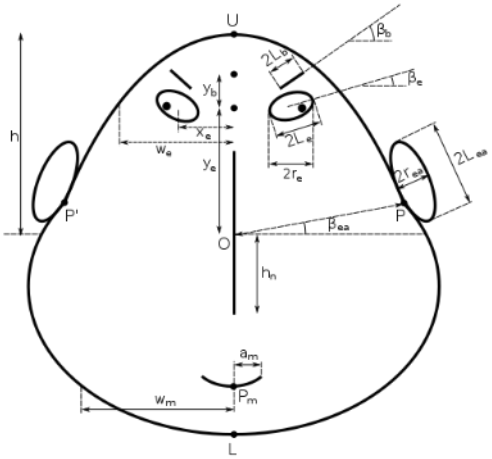

(https://upload.wikimedia.org/wikipedia/commons/1/17/Chernoff_faces_for_evaluations_of_US_judges.svg, 2017)

Chernoff Faces: Visualisierung hochdimensionaler Daten

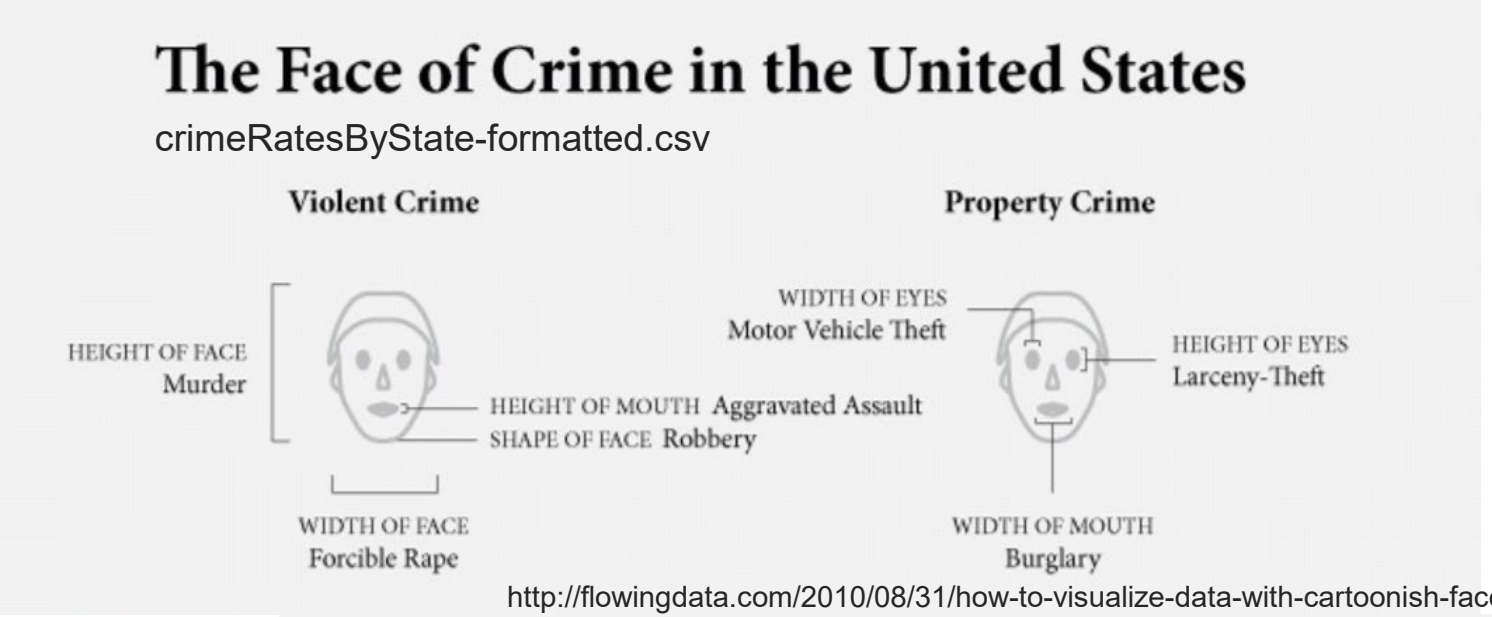

http://flowingdata.com/2010/08/31/how-to-visualize-data-with-cartoonish-faces/crime-chernoff-faces-by-state-edited-2/

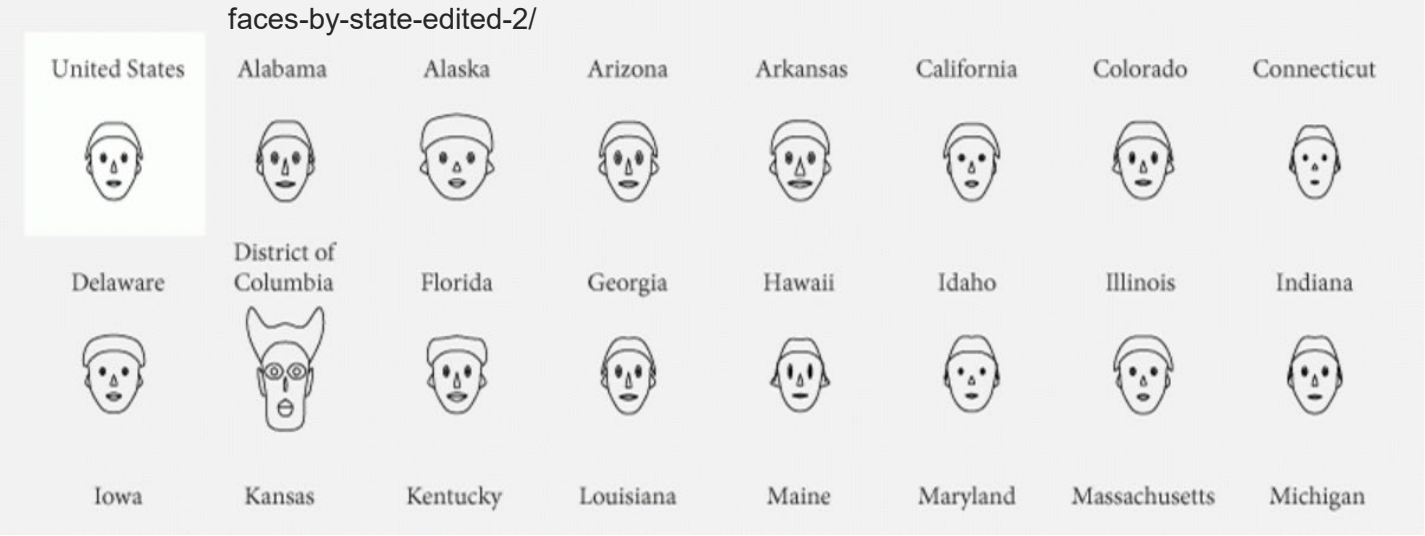

Chernoff Faces: Visualisierung hochdimensionaler Daten

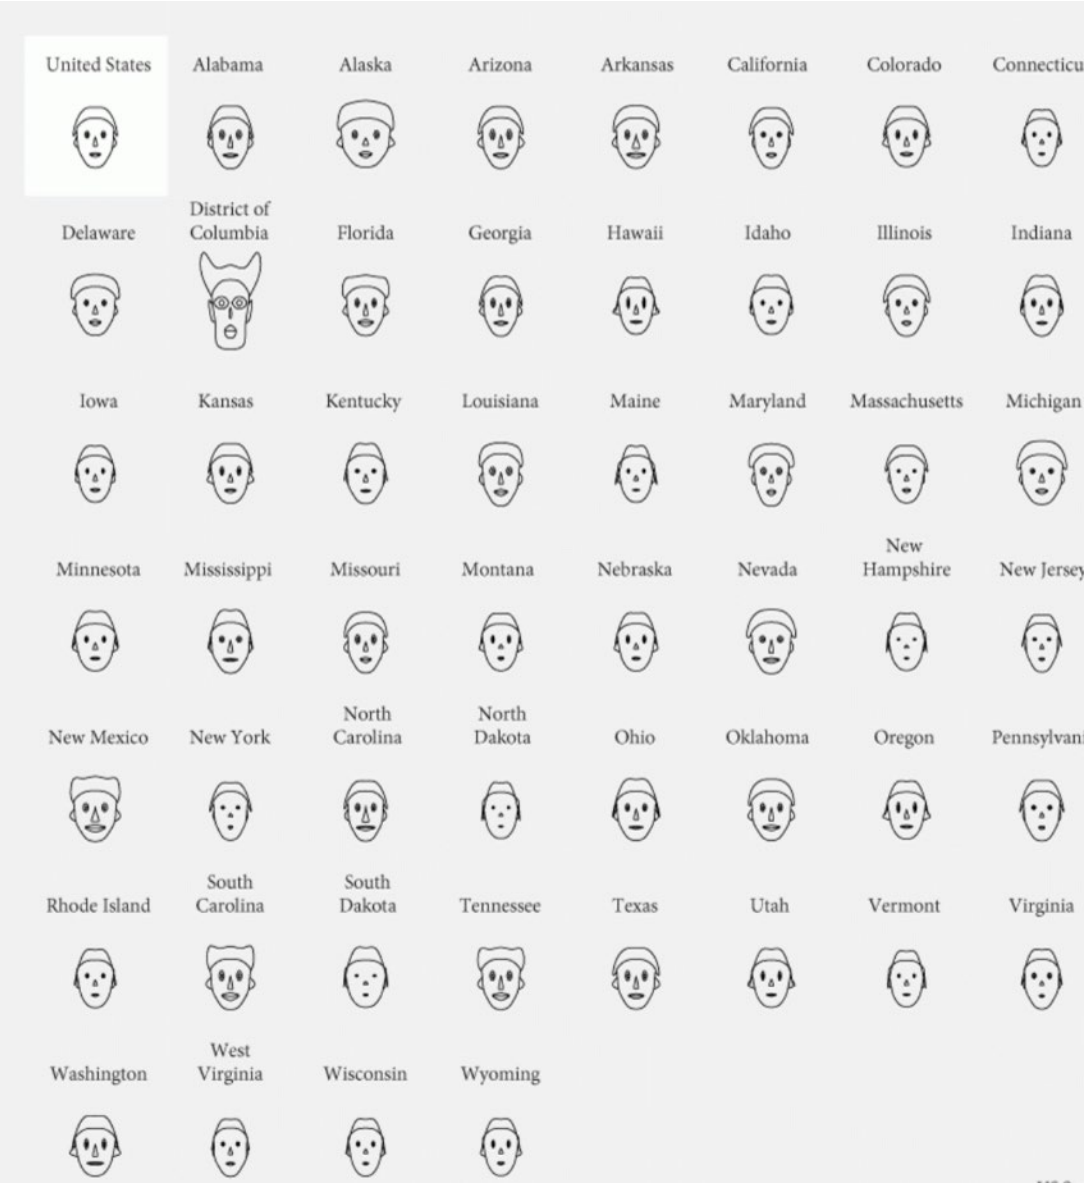

Chernoff Faces: Visualisierung hochdimensionaler Daten

Beispiel Kriminalität USA

Mapping (pro Staat, auf 0–1 normiert):

- Total Crime Rate → Mundkrümmung (hoch ⇒ trauriger Mund)
- Violent Crime Rate → Augengröße
- Property Crime Rate → Gesichtsbreite

Schneller Befund (Top/Bottom nach Gesamt-Rate, per 100 000 Einw.):

- Höchste Gesamt-Raten: District of Columbia, New Mexico, Alaska, Louisiana, South Carolina
- Niedrigste Gesamt-Raten: Maine, New Hampshire, Idaho, Massachusetts, New Jersey
- Höchste Gewalt-Rate: D.C., Alaska, New Mexico, Tennessee, Arkansas

Daten: state_crime.csv

Chernoff Faces: Visualisierung hochdimensionaler Daten

Titanic Datensatz

Mapping (je Gruppenmittelwert, auf 0–1 normalisiert):

- Fare → Gesichtsbreite
- Age → Augengröße (jünger ⇒ größere Augen)
- Pclass → Augenabstand (1. Klasse ⇒ größer)
- Survived → Mundkrümmung (lacht bei hoher Überlebensquote)
- SibSp → Augenbrauenwinkel
- Parch → Nasenlänge

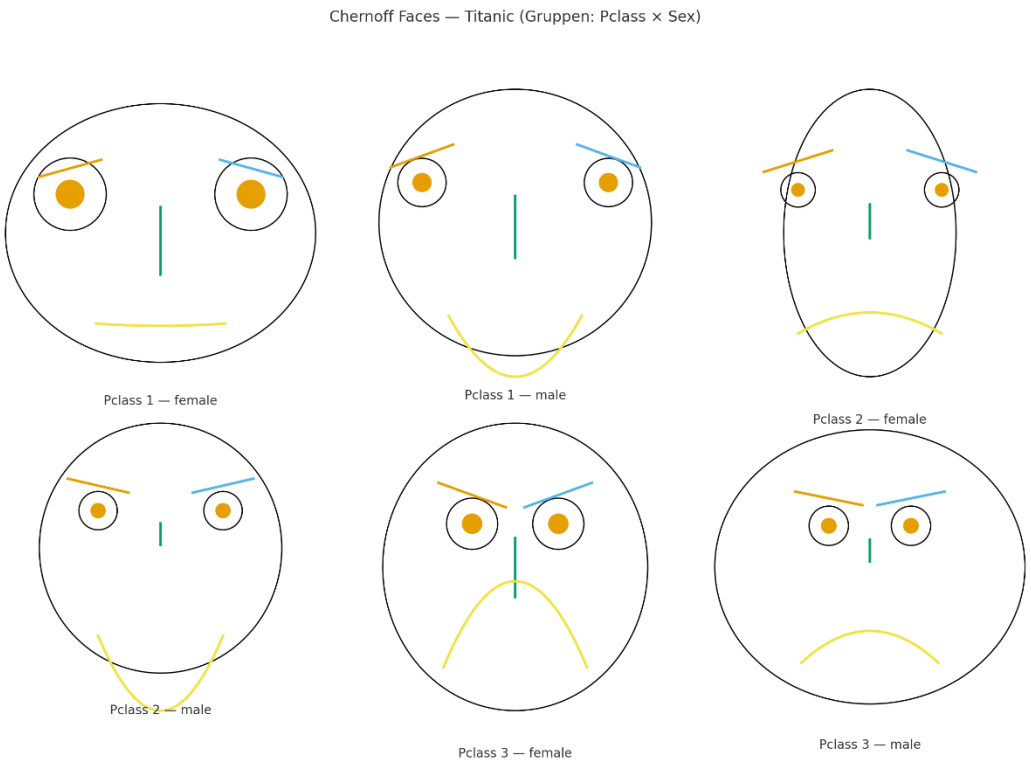

3D-Cluster-/Embedding-Visualisierung mit Glyphen

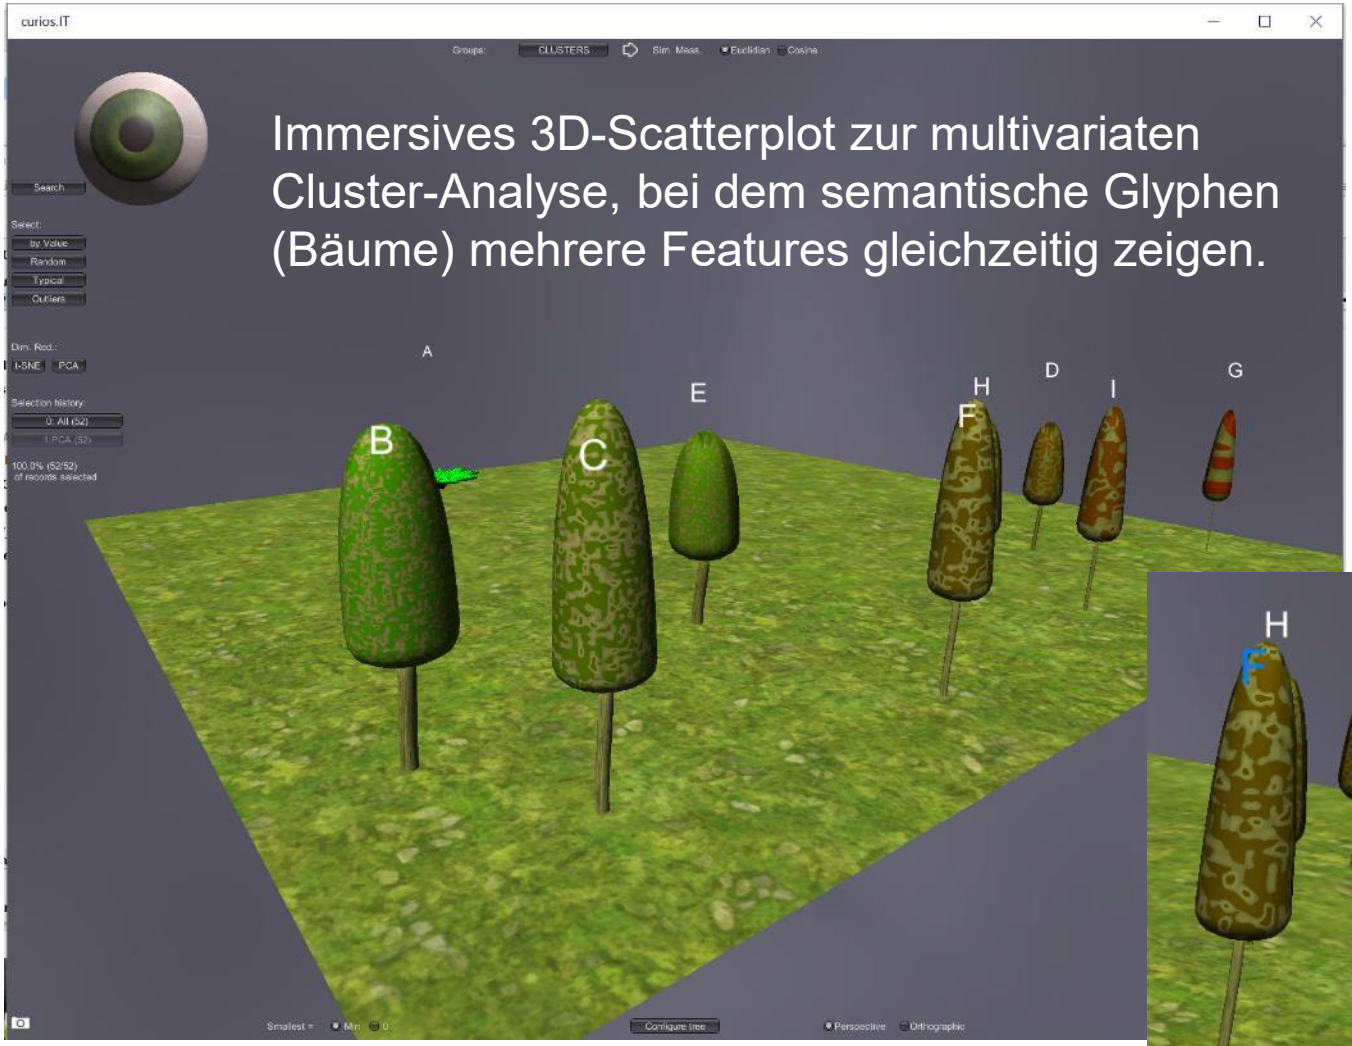

Immersives 3D-Scatterplot zur multivariaten Cluster-Analyse, bei dem semantische Glyphen (Bäume) mehrere Features gleichzeitig zeigen.

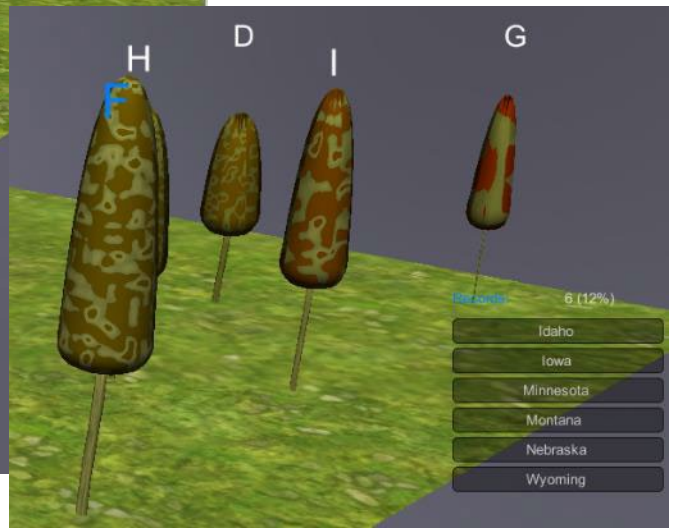

https://www.microsoft.com/de-de/p/curiosit/9pf5w73901cb?activetab=pivot%3aoverviewtab
http://kanohi.ch/data_exploration_solutions/

crimeRatesByState-formatted.csv

3D-Cluster-/Embedding-Visualisierung mit Glyphen

- Die Punkte (hier: Baum-Glyphen) repräsentieren Datensätze.
- Die 2D/3D-Position entsteht durch ein Dimensionalitäts-Reduktionsverfahren wie t-SNE oder PCA (siehe links).
- Ähnliche Objekte liegen nahe beieinander (Distanzmetrik: Euclidean oder Cosine).
- Form, Textur, Farbe, Größe der “Bäume” codieren zusätzliche Variablen (multivariate Glyphen).
- Die Buchstaben (A, B, C, …) markieren Cluster/Gruppe.

- Vorteile: intuitives Cluster-Gefühl, viele Variablen pro Objek
- Nachteile: Okklusion/Überladung, schwer quantifizierbar ohne Interaktion.

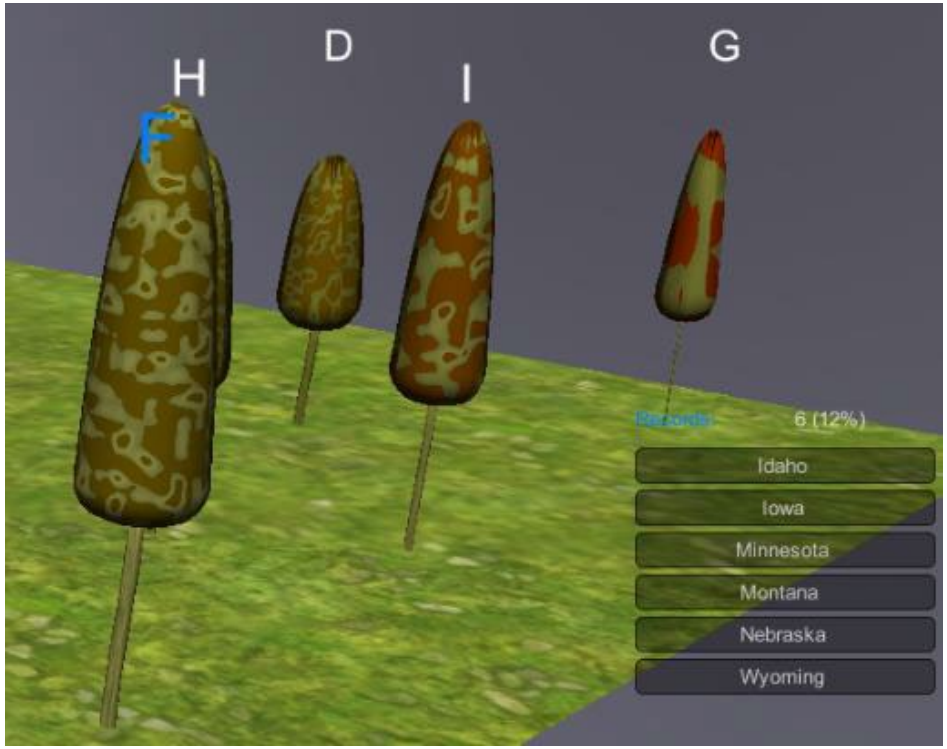

3D-Cluster-/Embedding-Visualisierung mit Glyphen

Beispiel Kriminalität USA

Mapping

- Position (x,y): PCA-Embedding aus (violent, property, total)
- Höhe der Krone: total crime rate
- Farb-/Helligkeitston: violent crime rate (höher ⇒ dunkler)
- Texturmuster (Ringdichte): property crime rate (mehr ⇒ dichter gestreift)
- Label: Bundesstaats-Abkürzung

3D-Embedding mit Baum-Glyphen
Pos: PCA(violent, property, total) | Höhe: total | Farbe: violent | Muster: property

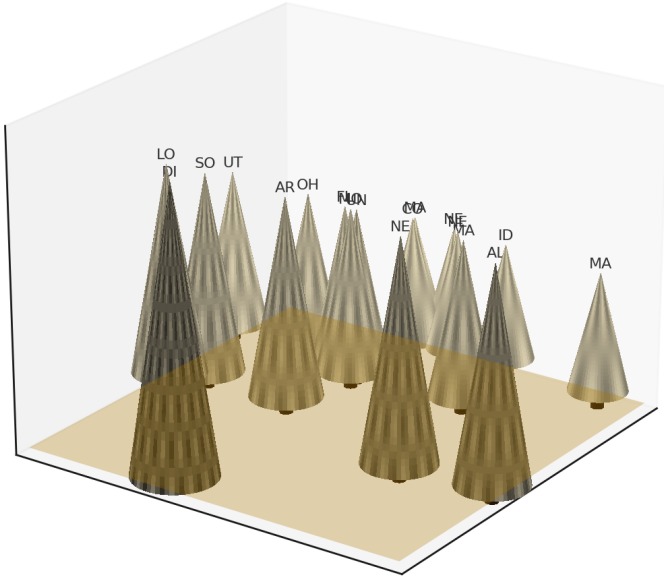

Daten: state_crime.csv

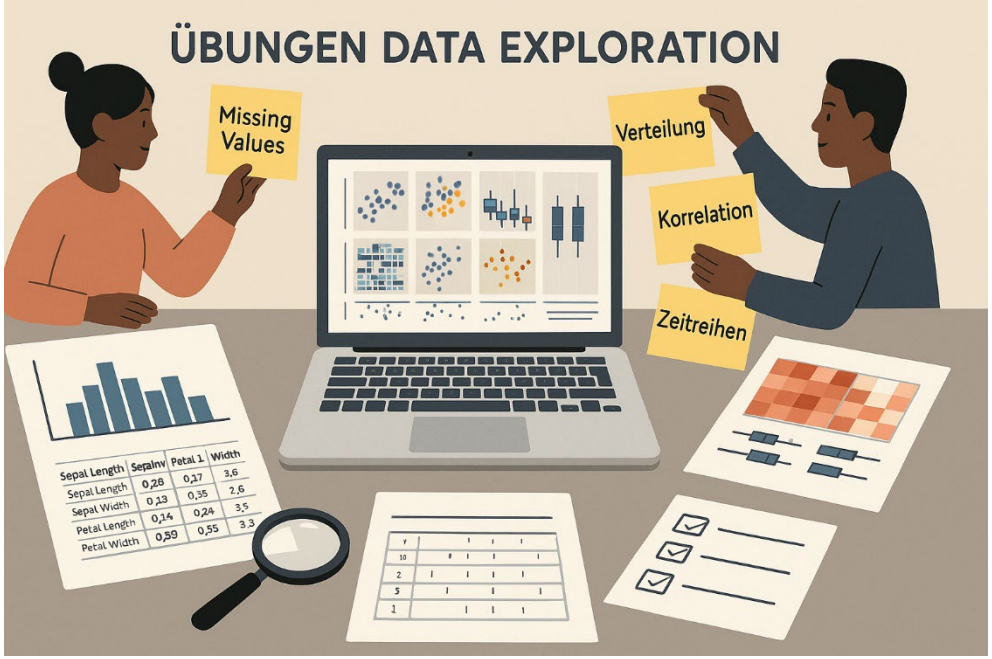
ÜBUNGEN DATA EXPLORATION
Missing Values
Verteilung
Korrelation
Zeitreihen

7. Übungen

Übung 1a: Datenanalyse

Aufgabe 1

Analysieren und präsentieren Sie Titanic- und Iris-Daten!

- Welche Variablen kommen vor?
- Welche Datenqualität? Maßzahlen? (sh. Übung 1 und 2)
- Ermitteln Sie wichtigsten Kennzahlen für Daten!
- Visualisieren Sie die Daten!
- Welche Schlüsse können Sie ziehen?
- Was kann man den Daten entnehmen?
- Wofür könnte man sie einsetzen?

Aufgabe 2

Suchen und verwenden Sie einen interessanten, neuen Visualisierungsansatz

Übung 1a: Maßskalen - Titanic Dataset

Variable	Art	Skala
Passenger Class		
Name		
Sex		
Age		
No. of Siblings or Spouses on Board		
No. of Parents or Children on Board		
Ticket Number		
Passenger Fare		
Cabin		
Port of embarkation		
Life boat		
Survived		

Übung 1a: Maßskalen - Titanic Dataset - Lösung

Übung 1b: Maßskalen – Iris Datensatz

Variable	Art	Skala
Länge des Kelchblatts		
Breite des Kelchblatts		
Länge des Kronblatts		
Breite des Kronblatts		
Art		

Übung 1b: Maßskalen – Iris Datensatz Lösung

Übung 1c :Lage und Streuungsparameter - Titanic Dataset

Variable	Modus	Median	Arithmetisches Mittel
Passenger Class			
Age			
No. of Siblings or Spouses on Board			
No. of Parents or Children on Board			
Passenger Fare			

Variable	Spannweite	Stichprobenvarianze	Standardabweichung
Passenger Class			
Age			
No. of Siblings or Spouses on Board			
No. of Parents or Children on Board			
Passenger Fare			

Übung 1c :Lage und Streuungsparameter - Iris Dataset

Variable	Modus	Median	Arithmetisches Mittel
Länge des Kelchblatts			
Breite des Kelchblatts			
Länge des Kronblatts			
Breite des Kronblatts			

Variable	Spannweite	Stichprobenvarianze	Standardabweichung
Länge des Kelchblatts			
Breite des Kelchblatts			
Länge des Kronblatts			
Breite des Kronblatts			